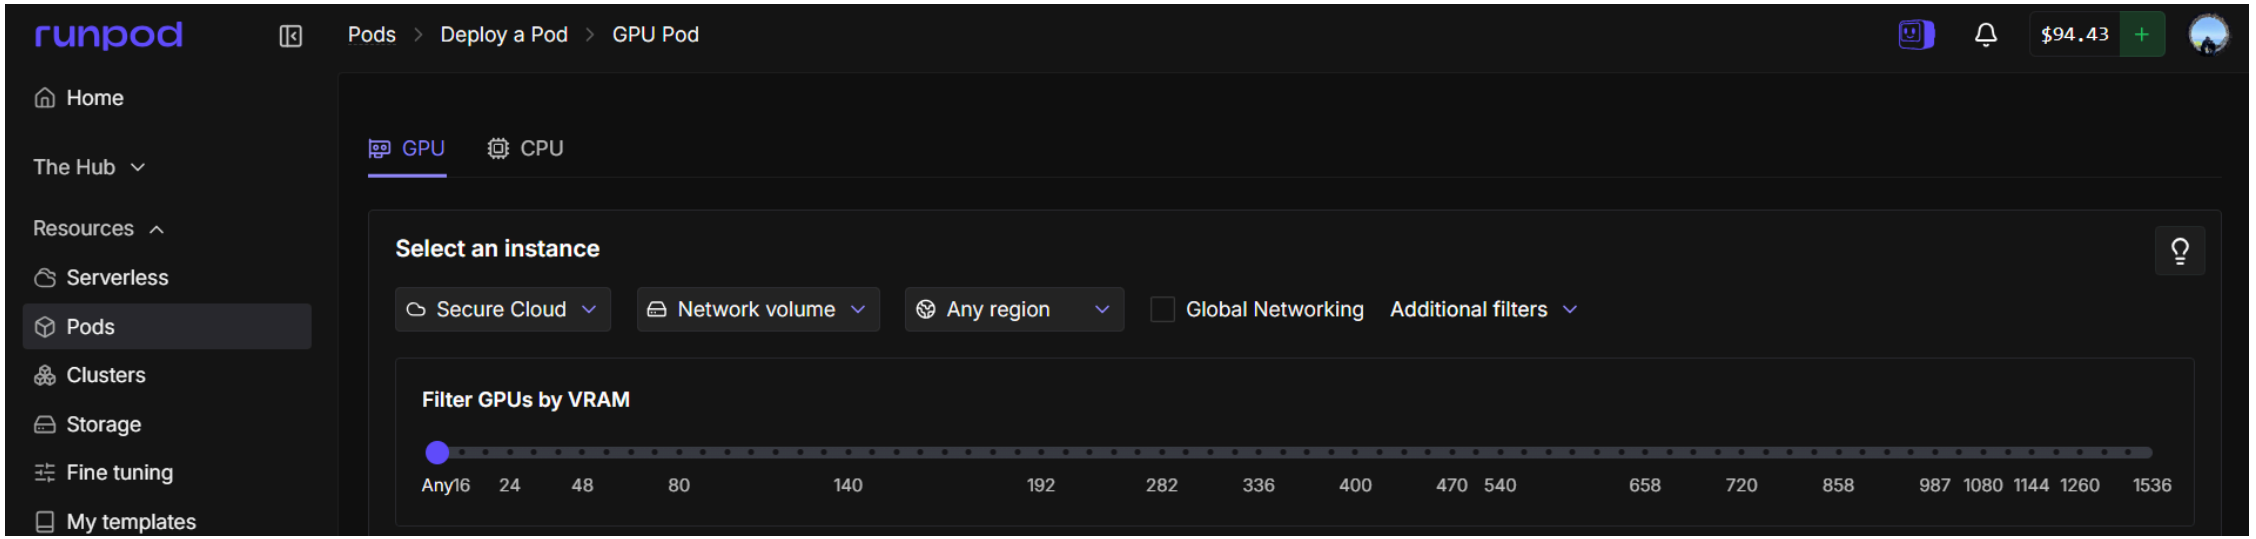
Pods

- Pod는 쉽게 말해 클라우드에서 빌려 쓰는 GPU 컴퓨터입니다.
- 내 컴퓨터에 GPU가 없어도, RunPod에서 Pod를 만들면 강력한 GPU가 달린 서버를 바로 사용할 수 있습니다.



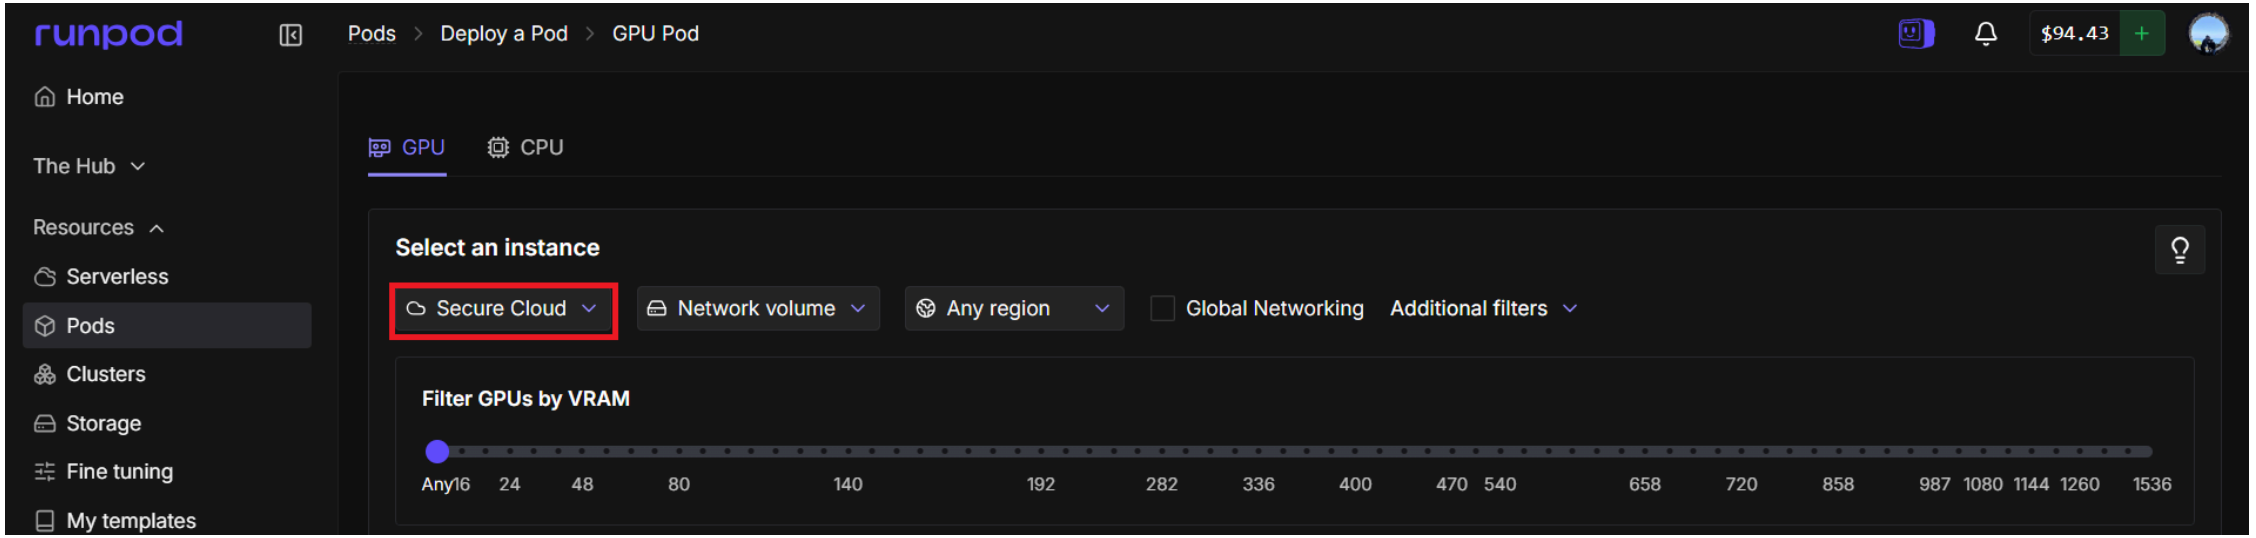
GPU Pod 설정 옵션 가이드

상황	추천 설정
일반 AI 학습	Secure Cloud + Any Region
비용 절감	Community Cloud
데이터 재사용	Network Volume 연결
멀티 노드 학습	Global Networking 활성화
대형 모델 실행	VRAM 슬라이더 80GB 이상

Secure Cloud

- **무엇인가?** GPU 서버가 위치한 **클라우드 환경**을 선택하는 옵션
- **Secure Cloud** → 보안이 강화된 데이터센터 (기본값)
- **Community Cloud** → 개인이 제공하는 서버 (더 저렴하지만 보안 낮음)

> 중요한 작업이라면 Secure Cloud, 비용 절감이 목적이라면 Community Cloud 선택



Network Volume

- **무엇인가?** Pod에 연결할 **외부 저장소(디스크)**를 선택하는 옵션
- Pod를 종료해도 데이터가 **사라지지 않고 유지**됨
- 여러 Pod 간에 **같은 데이터를 공유** 가능

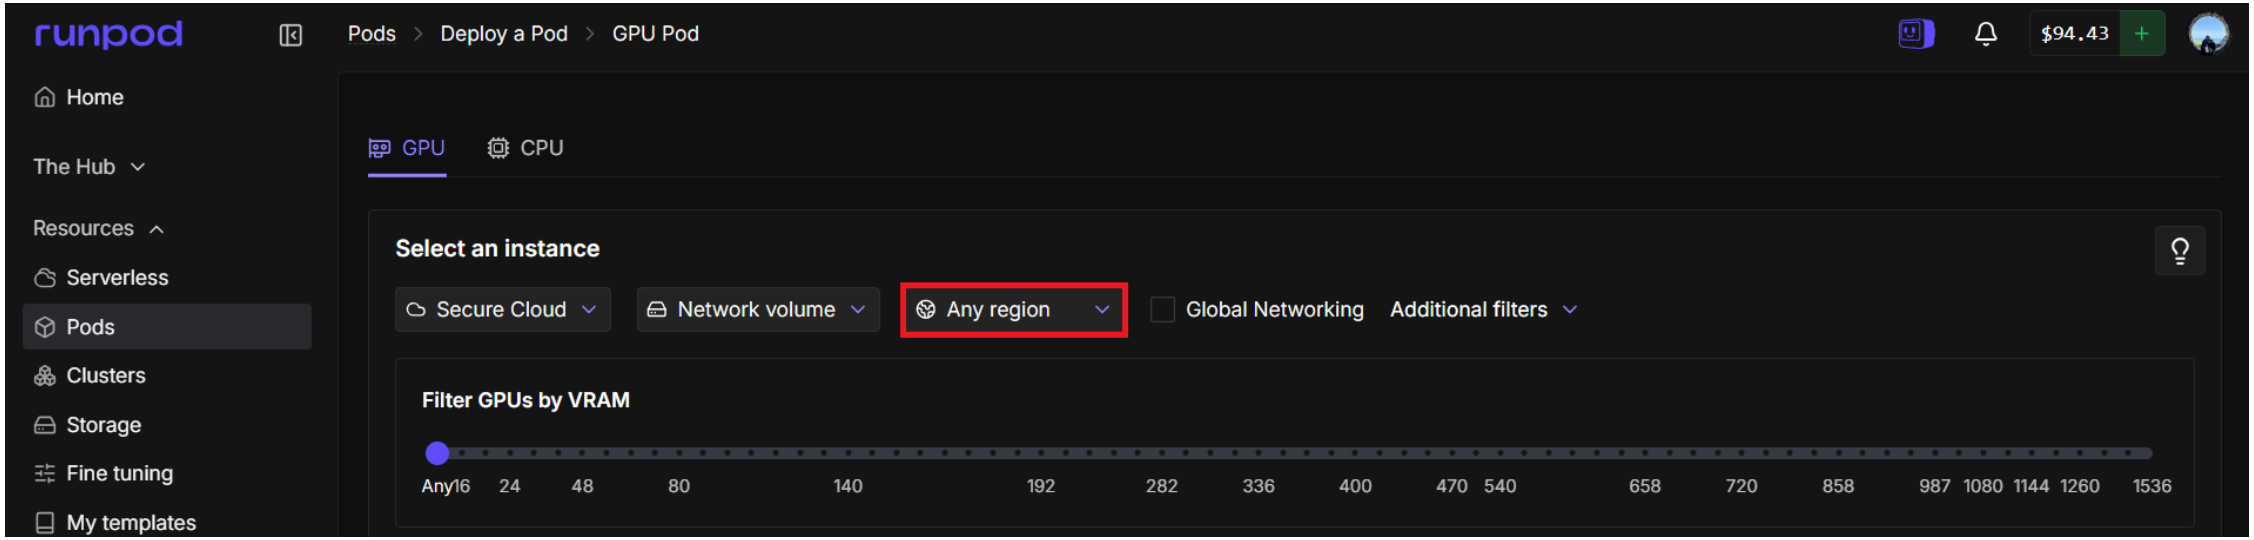
> 모델 파일, 데이터셋처럼 용량 큰 파일을 반복 사용할 때 유용



Any Region

- **무엇인가?** GPU 서버가 있는 **지역(국가/대륙)**을 선택하는 옵션
- `Any Region` → 전 세계 어디든 가용한 서버 사용 (기본값)
- 특정 지역 선택 시 → 해당 지역 서버만 필터링

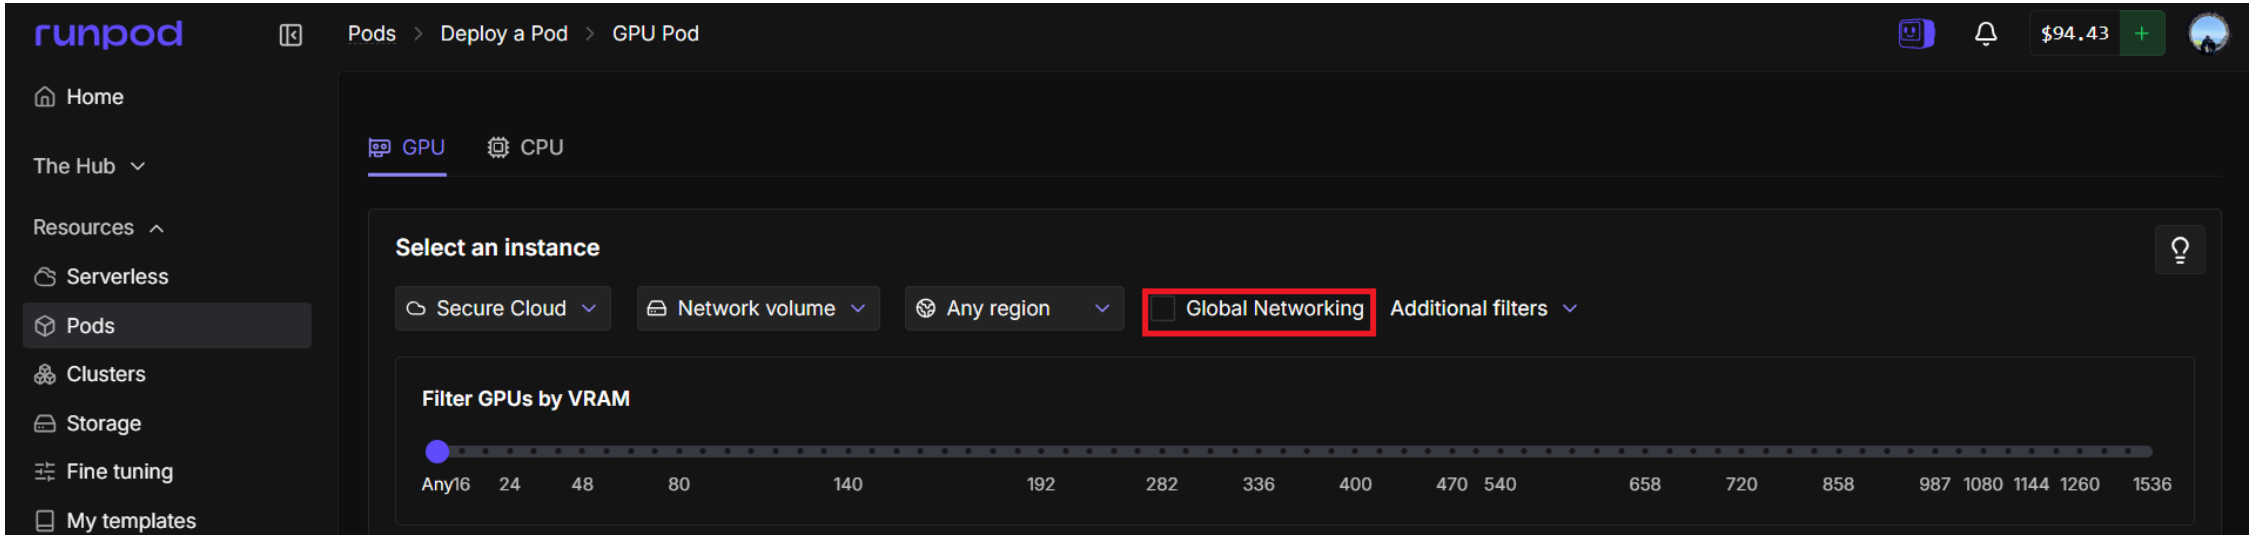
> 속도가 중요하다면 **가까운 지역** 선택, 가용성이 중요하다면 Any Region 유지



Global Networking

- **무엇인가?** Pod 간 **내부 네트워크 통신**을 가능하게 하는 옵션
- 체크 시 → 여러 Pod끼리 **빠른 내부망**으로 연결 가능
- 분산 학습(Multi-GPU/Multi-Node) 시 유용

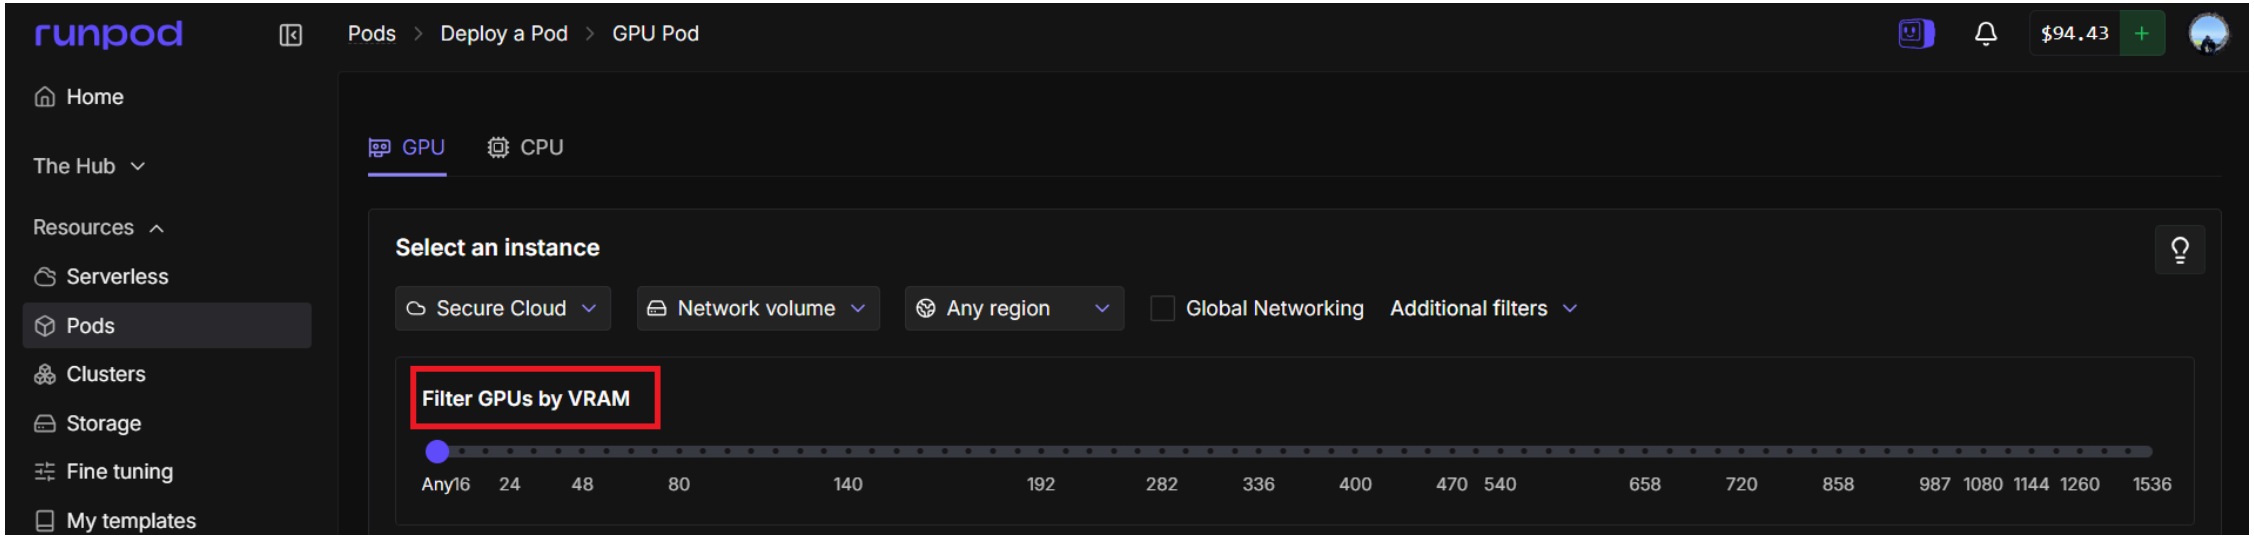
> 단일 GPU 작업이면 **체크 불필요**, 멀티 노드 학습이면 **체크 권장**



VRAM 필터 슬라이더

- **무엇인가?** 원하는 **최소 VRAM 용량**으로 GPU를 필터링
- 슬라이더를 오른쪽으로 이동할수록 고용량 GPU만 표시
- 범위: 16GB ~ 1536GB

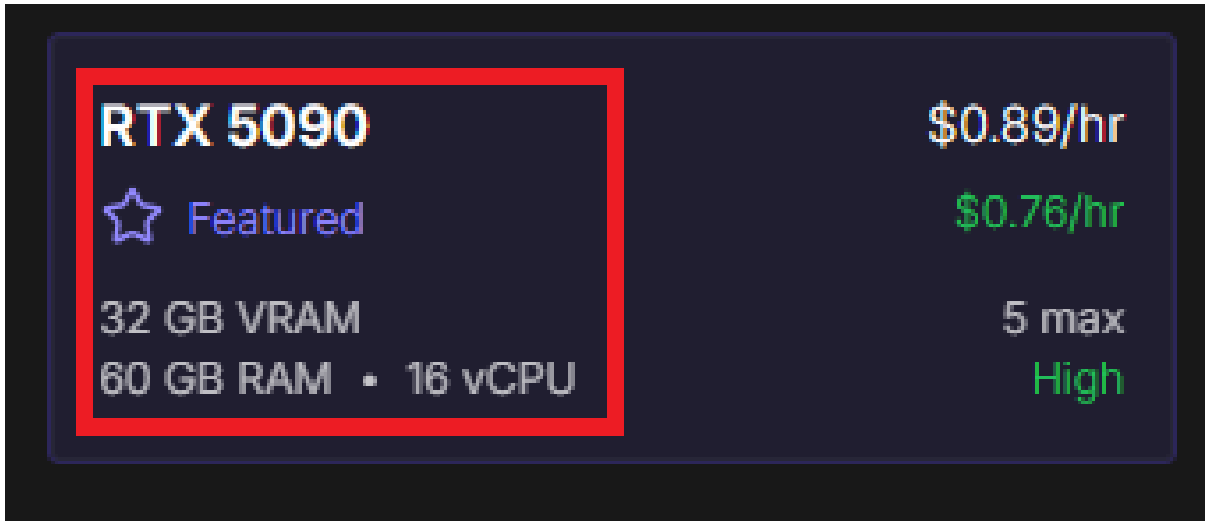
> 실행할 모델 크기에 맞는 VRAM 선택 (예: LLaMA 70B → 최소 80GB 권장)



GPU Pod 정보

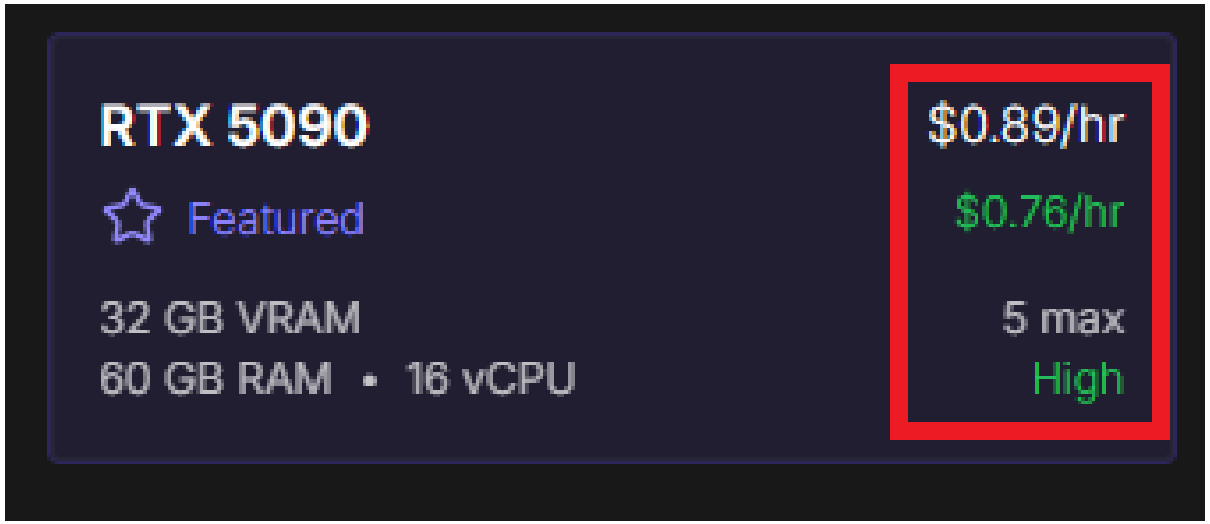
하드웨어 사양(성능)

- `RTX 5090` : 그래픽 카드(GPU)
- `32GB VRAM` : GPU RAM
- `60GB RAM` : CPU RAM
- `16 vCPU` : 가상 CPU 코어 수



가격 및 상태

- `$0.89/hr` : On-demand 가격
- `$0.76/hr` : Interruptible 가격
- `5 max` : 한 번에 최대 5대까지 빌리 수 있음
- `High` : 가용성(Availability) 상태



가용성(Availability) 상태

- `High (높음)` : 현재 해당 GPU 모델을 갖춘 서버가 아주 많이 남아 있다는 뜻입니다. 클릭하는 즉시 바로 서버를 빌려(Deploy) 작업을 시작할 수 있습니다.
- `Medium (중간)` : 재고가 어느 정도 있지만, 사용자가 몰리면 금방 매진될 수 있는 상태입니다.
- `Low (낮음)` : 재고가 거의 없습니다. 운 좋게 한두 대를 빌릴 수도 있지만, 대부분의 경우 "현재 사용 가능한 서버가 없습니다"라는 메시지를 보게 될 확률이 높습니다.

'Availability'가 왜 중요한가?

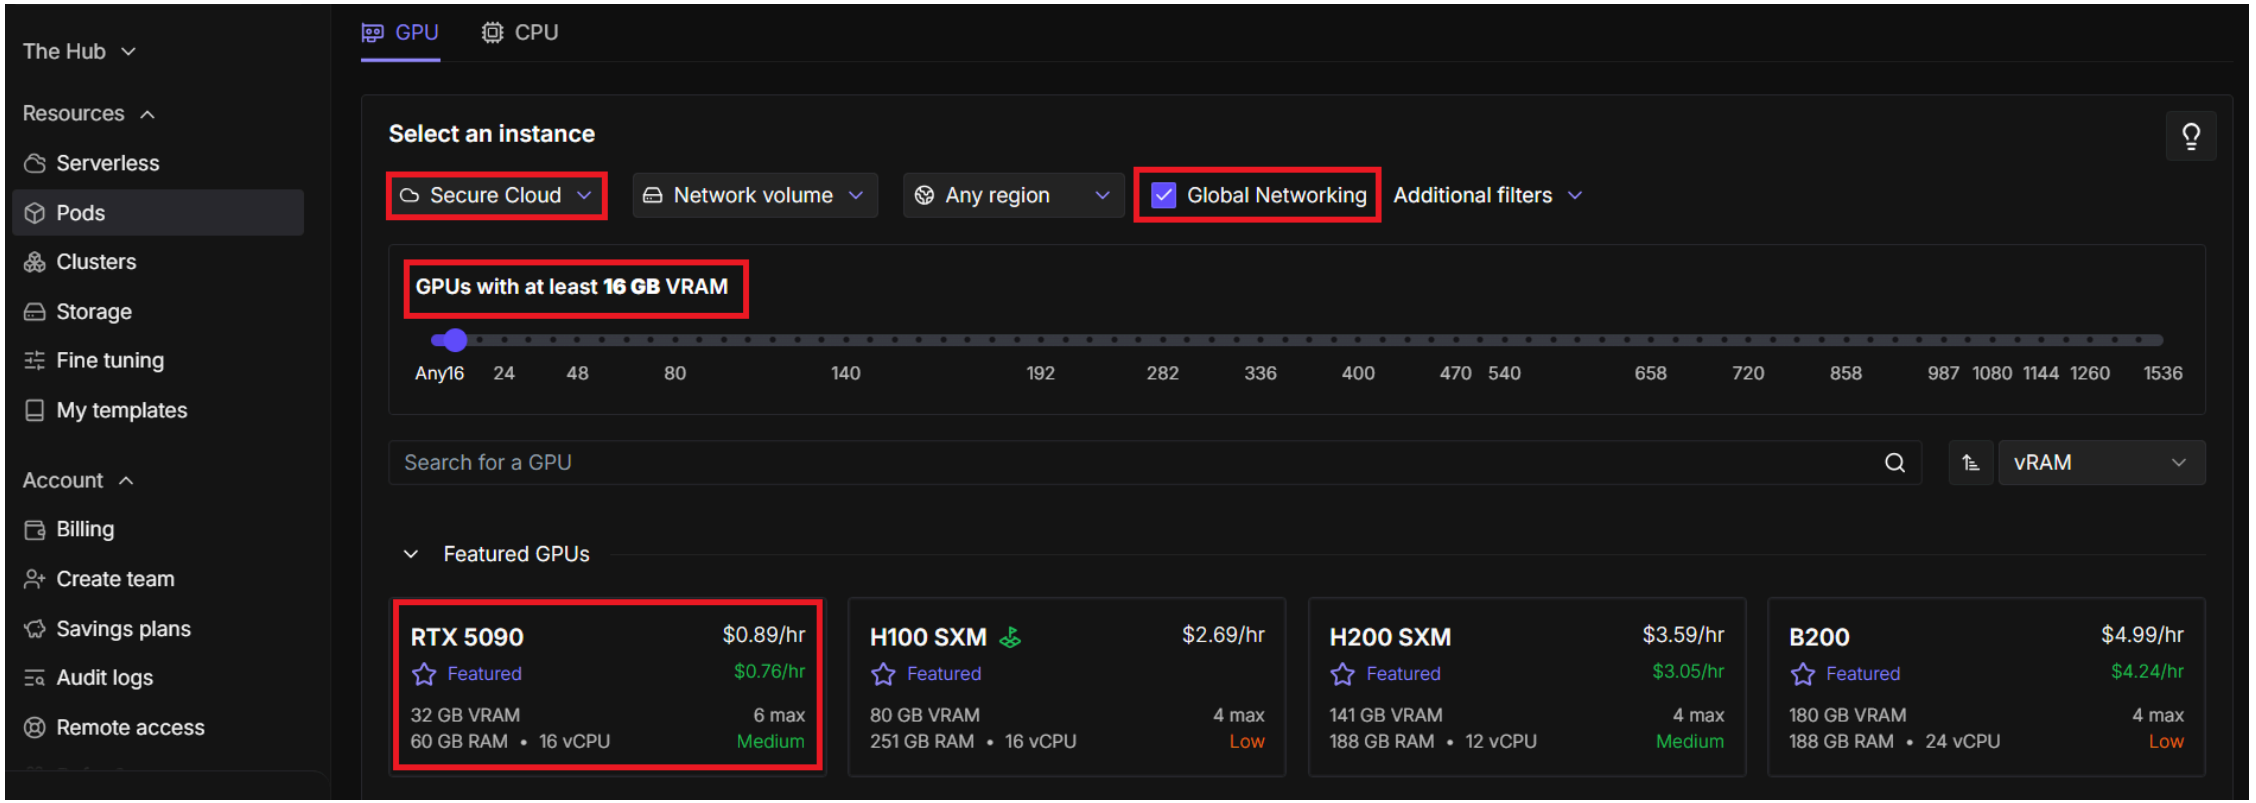
단순히 "빌릴 수 있다/없다"를 넘어, 여러분의 비용과 작업 안정성에 직접적인 영향을 미칩니다.

- `On-Demand (정가제)` 사용자:
  - 가용성이 **'High'**일 때 빌리면 작업 도중 서버가 끊길 걱정 없이 안정적으로 사용할 수 있습니다.
  - 하지만 재고가 아예 없으면 아무리 돈을 많이 내려고 해도 서버를 열 수 없습니다.
- `Interruptible (경매/할인제)` 사용자:
  - 이 방식은 남는 서버를 저렴하게 빌려 쓰는 구조입니다.
  - 가용성이 **'Low'**로 떨어지면, RunPod 시스템은 저렴하게 쓰고 있는 여러분의 서버를 강제로 회수해서 `정가를 내는(On-Demand) 사람`에게 넘겨줍니다. 즉, 내 작업이 예고 없이 중단될 위험이 커집니다.

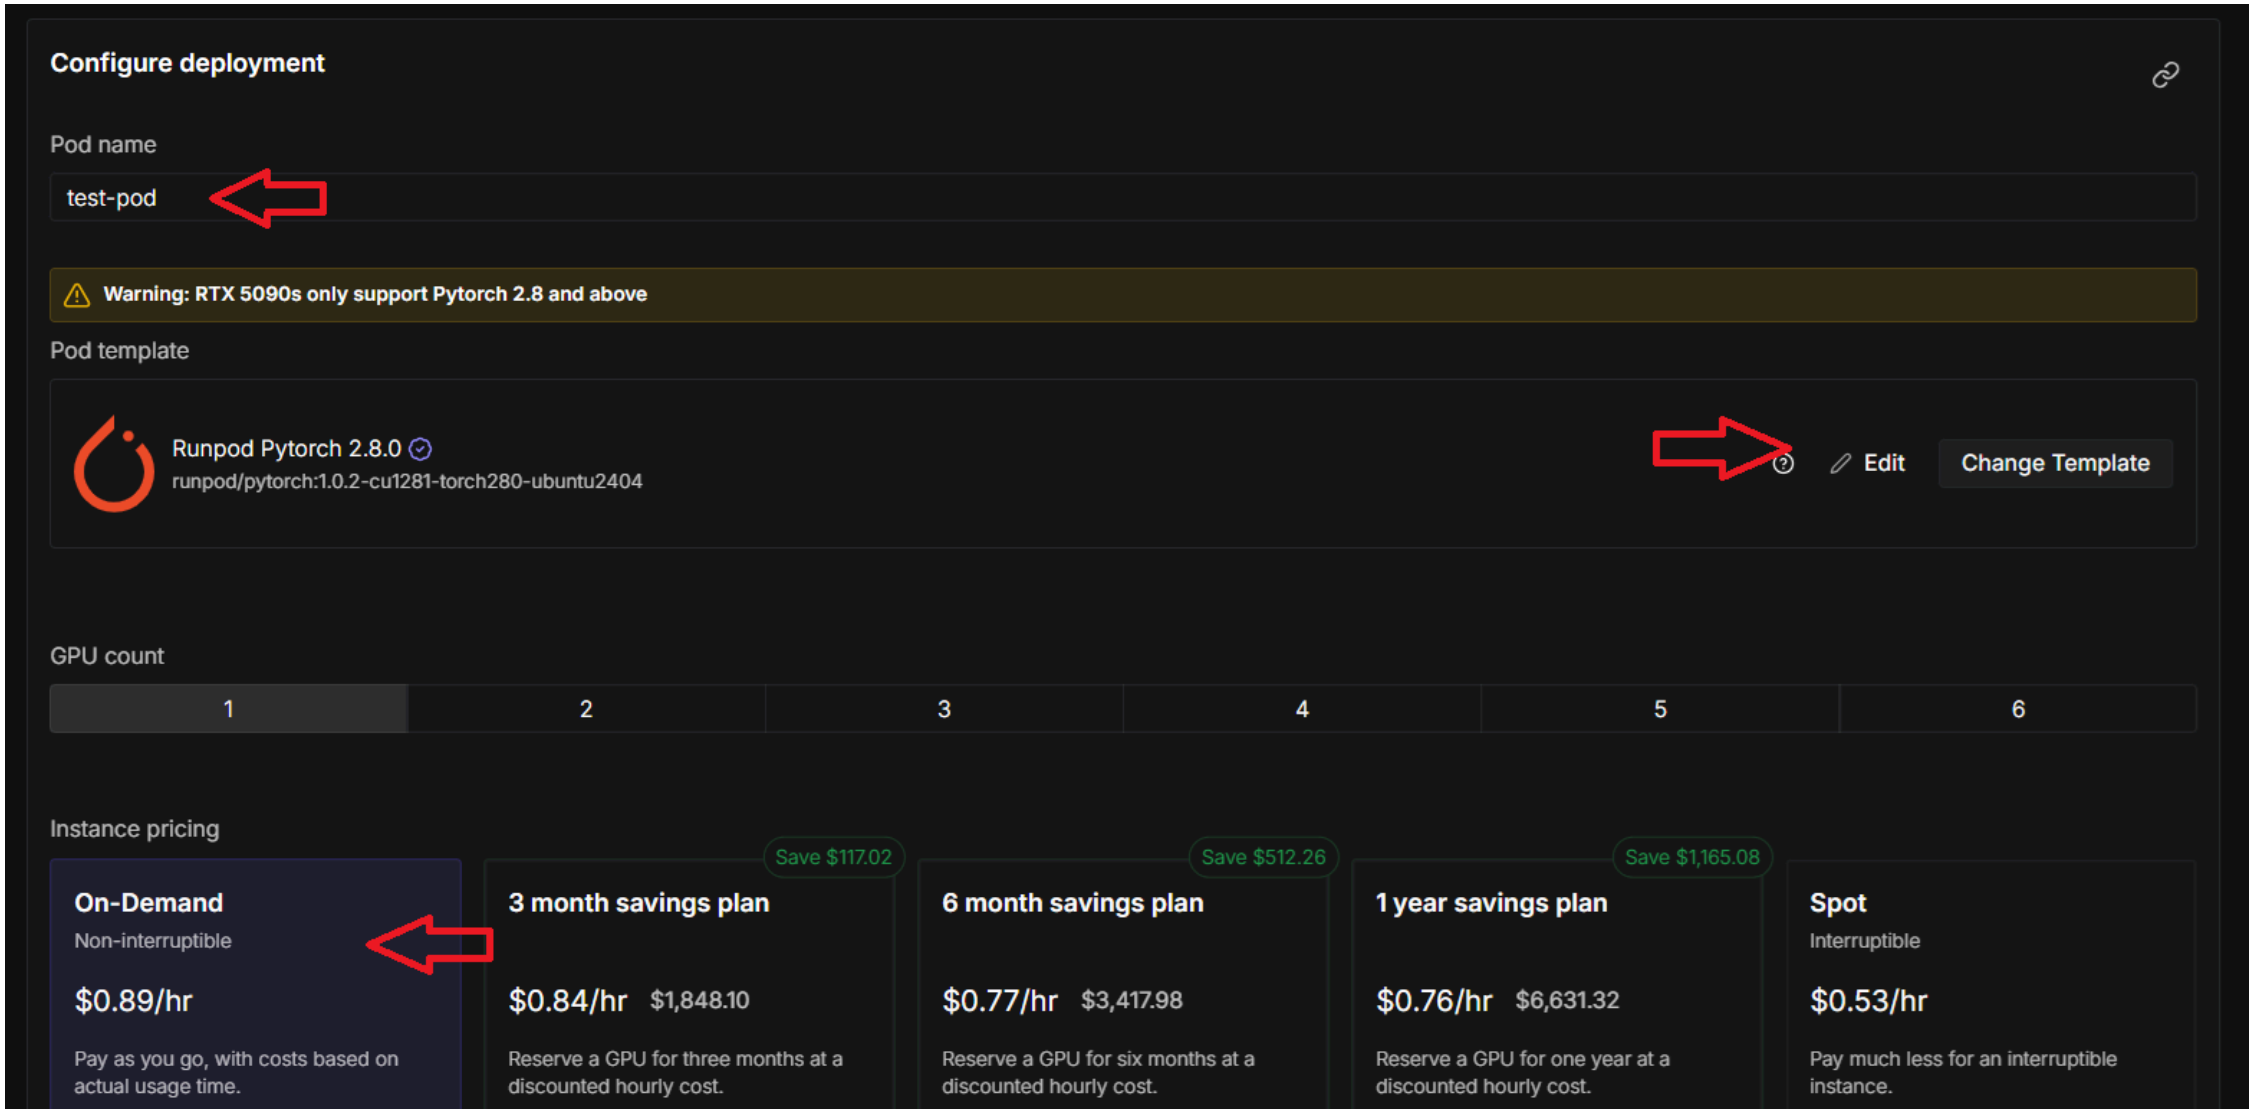
GPU Pod 실행

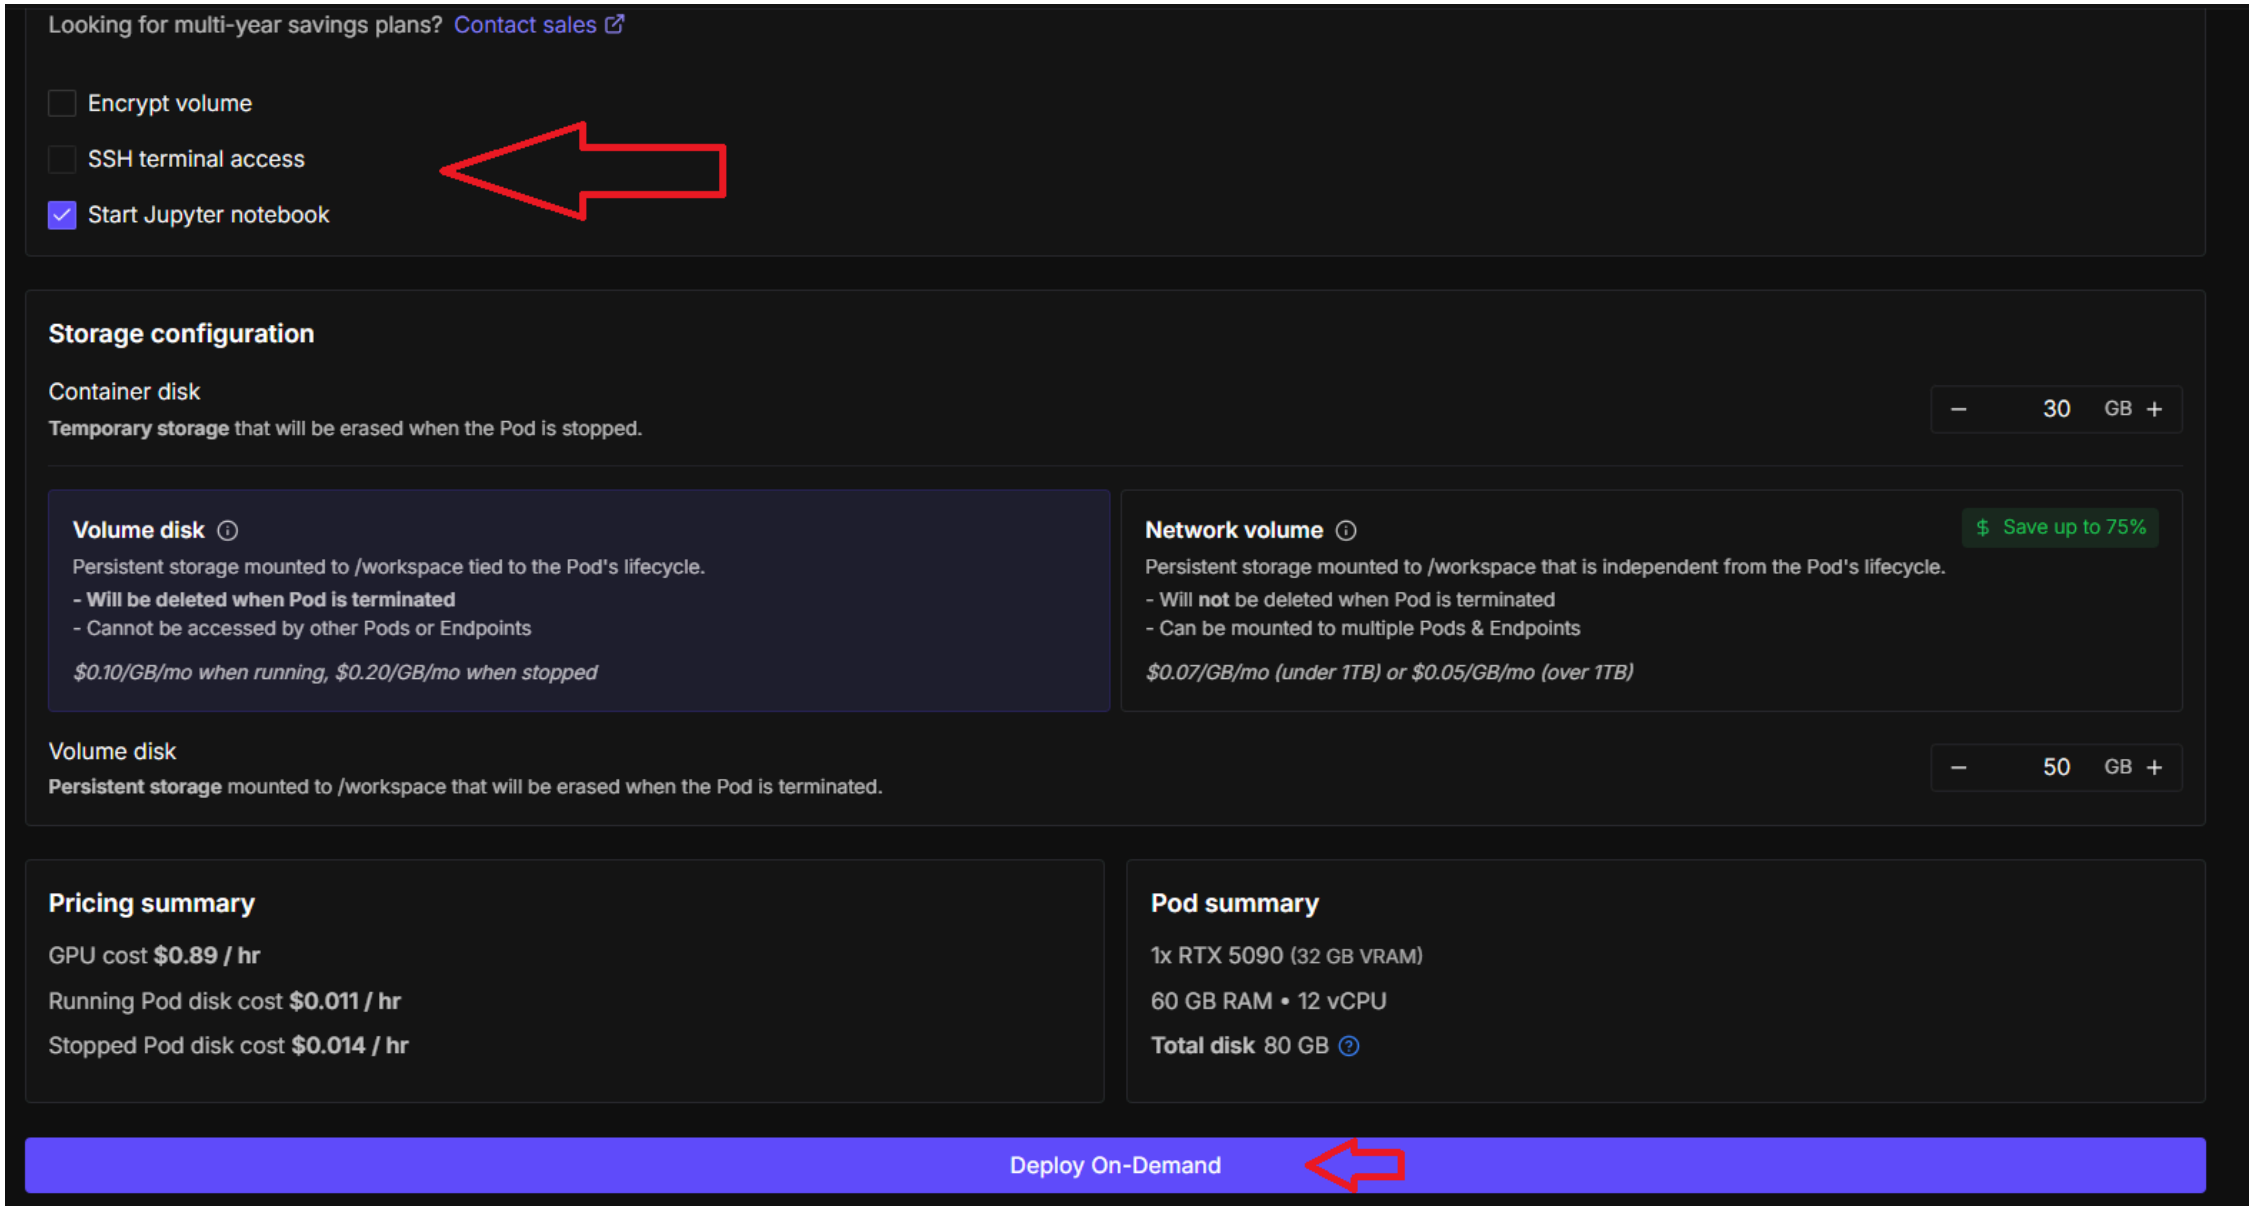
단계1: Pod 선택

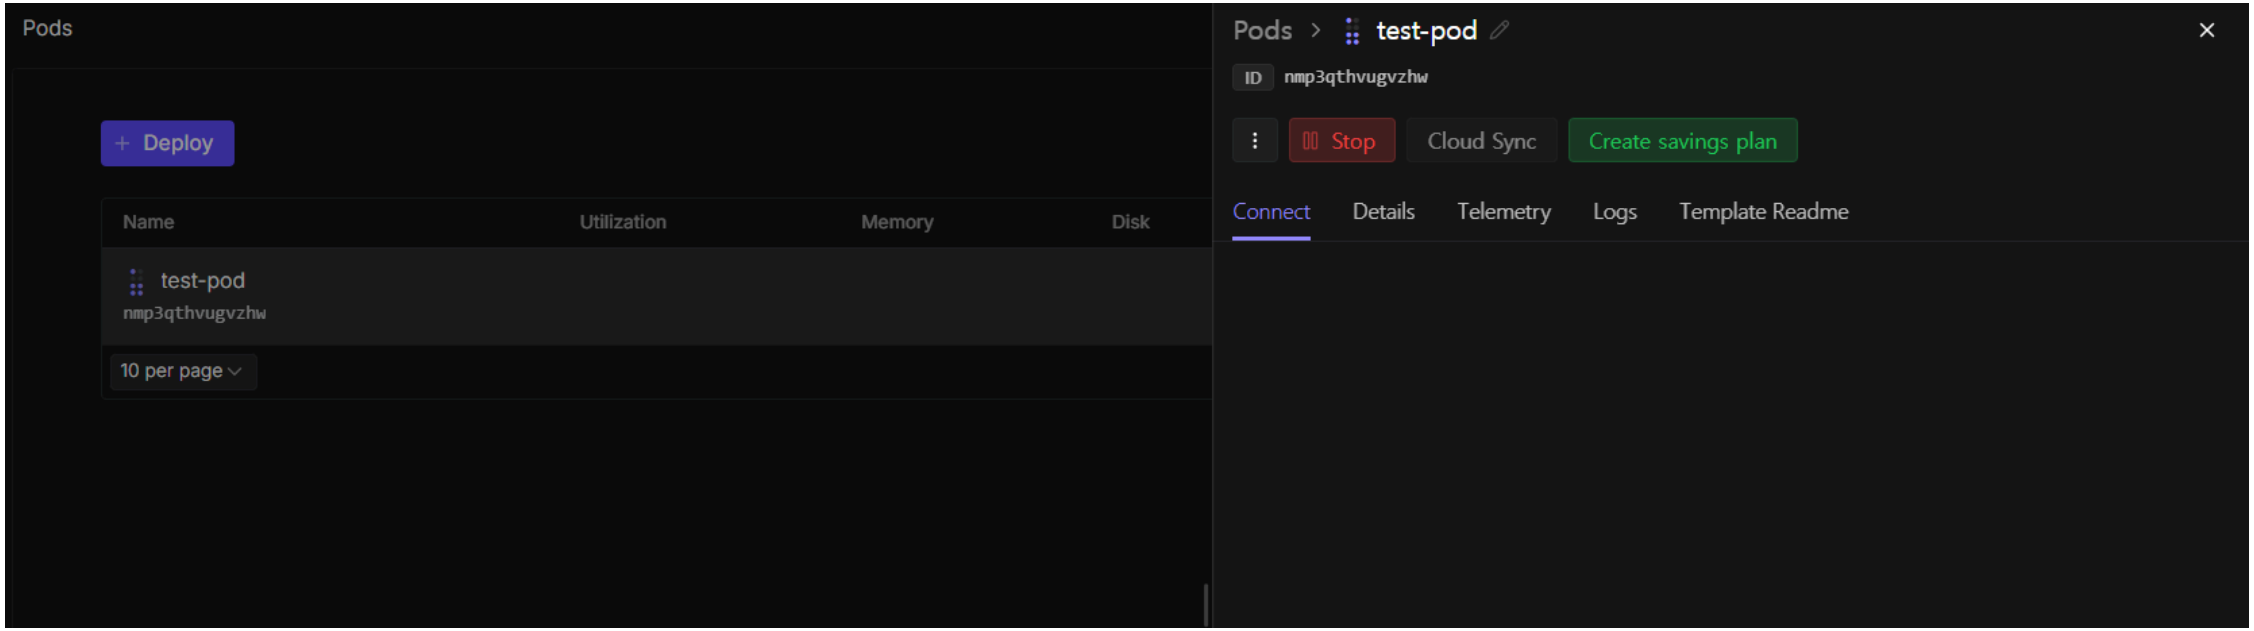
> RunPod의 GPU 종류별 요금 확인



단계2: Pod 실행

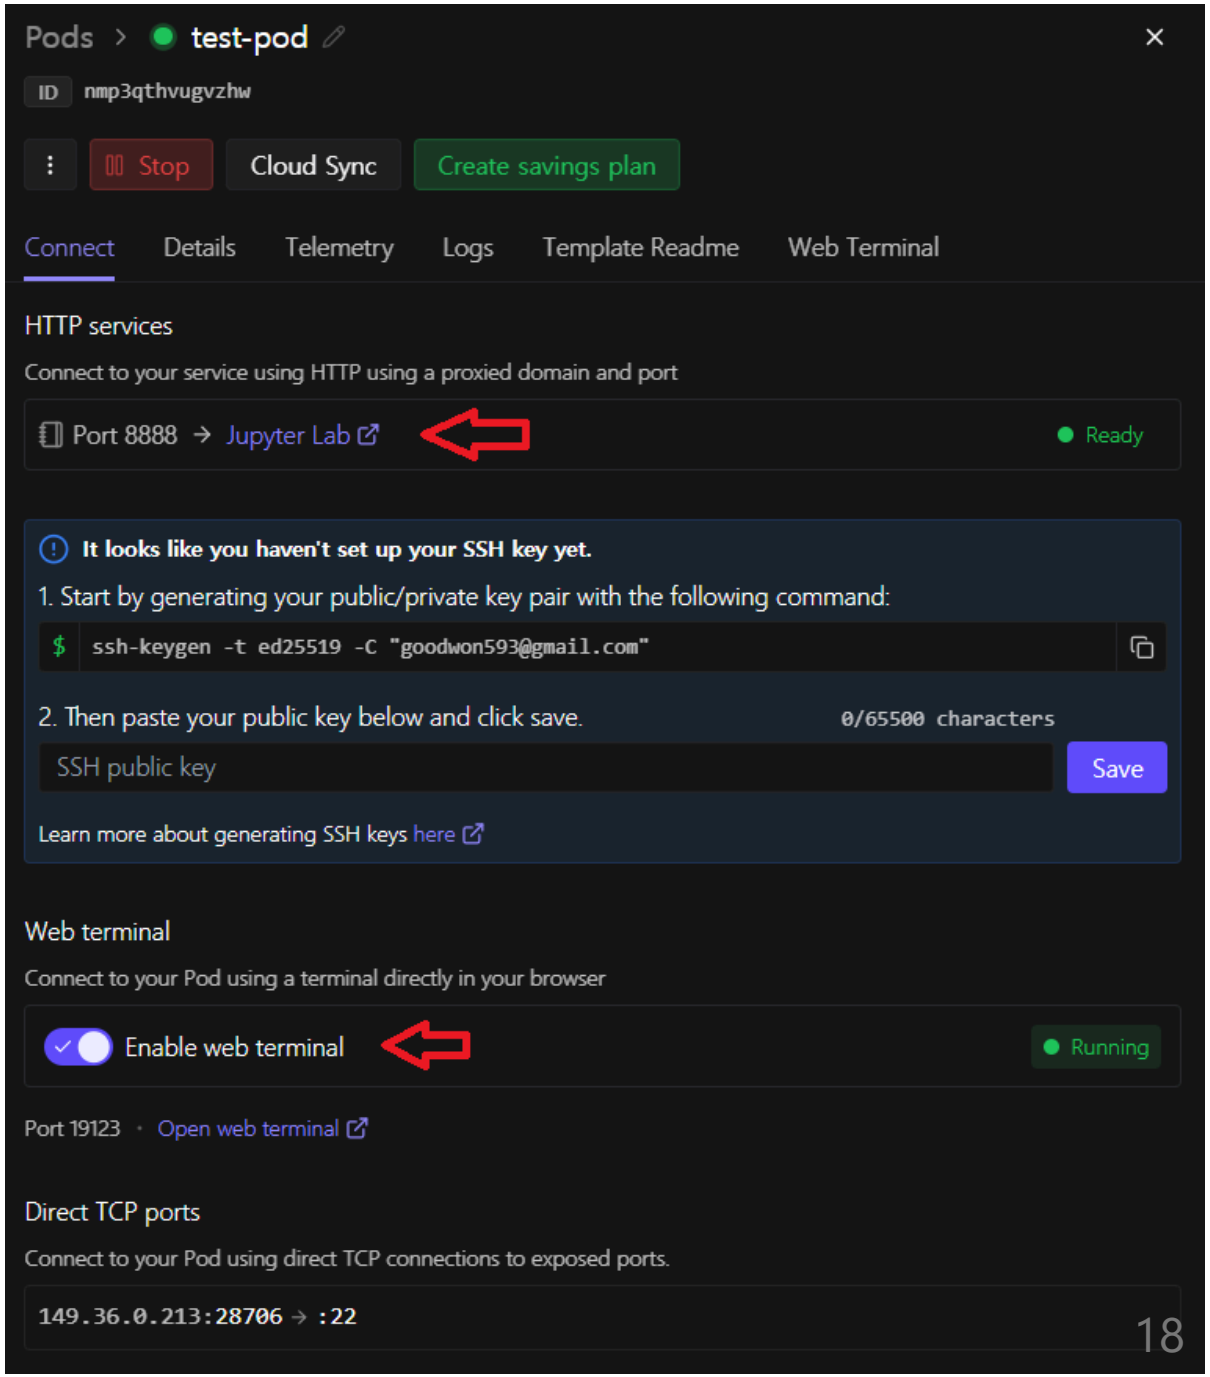

Configure deployment
Pod name
test-pod
Warning: RTX 5090s only support Pytorch 2.8 and above
Pod template
Runpod Pytorch 2.8.0
runpod/pytorch:1.0.2-cu1281-torch280-ubuntu2404
Edit
Change Template
GPU count
1
2
3
4
5
6
Instance pricing
On-Demand
Non-interruptible
$0.89/hr
Pay as you go, with costs based on actual usage time.
Save $117.02
3 month savings plan
$0.84/hr $1,848.10
Reserve a GPU for three months at a discounted hourly cost.
Save $512.26
6 month savings plan
$0.77/hr $3,417.98
Reserve a GPU for six months at a discounted hourly cost.
Save $1,165.08
1 year savings plan
$0.76/hr $6,631.32
Reserve a GPU for one year at a discounted hourly cost.
Spot
Interruptible
$0.53/hr
Pay much less for an interruptible instance.

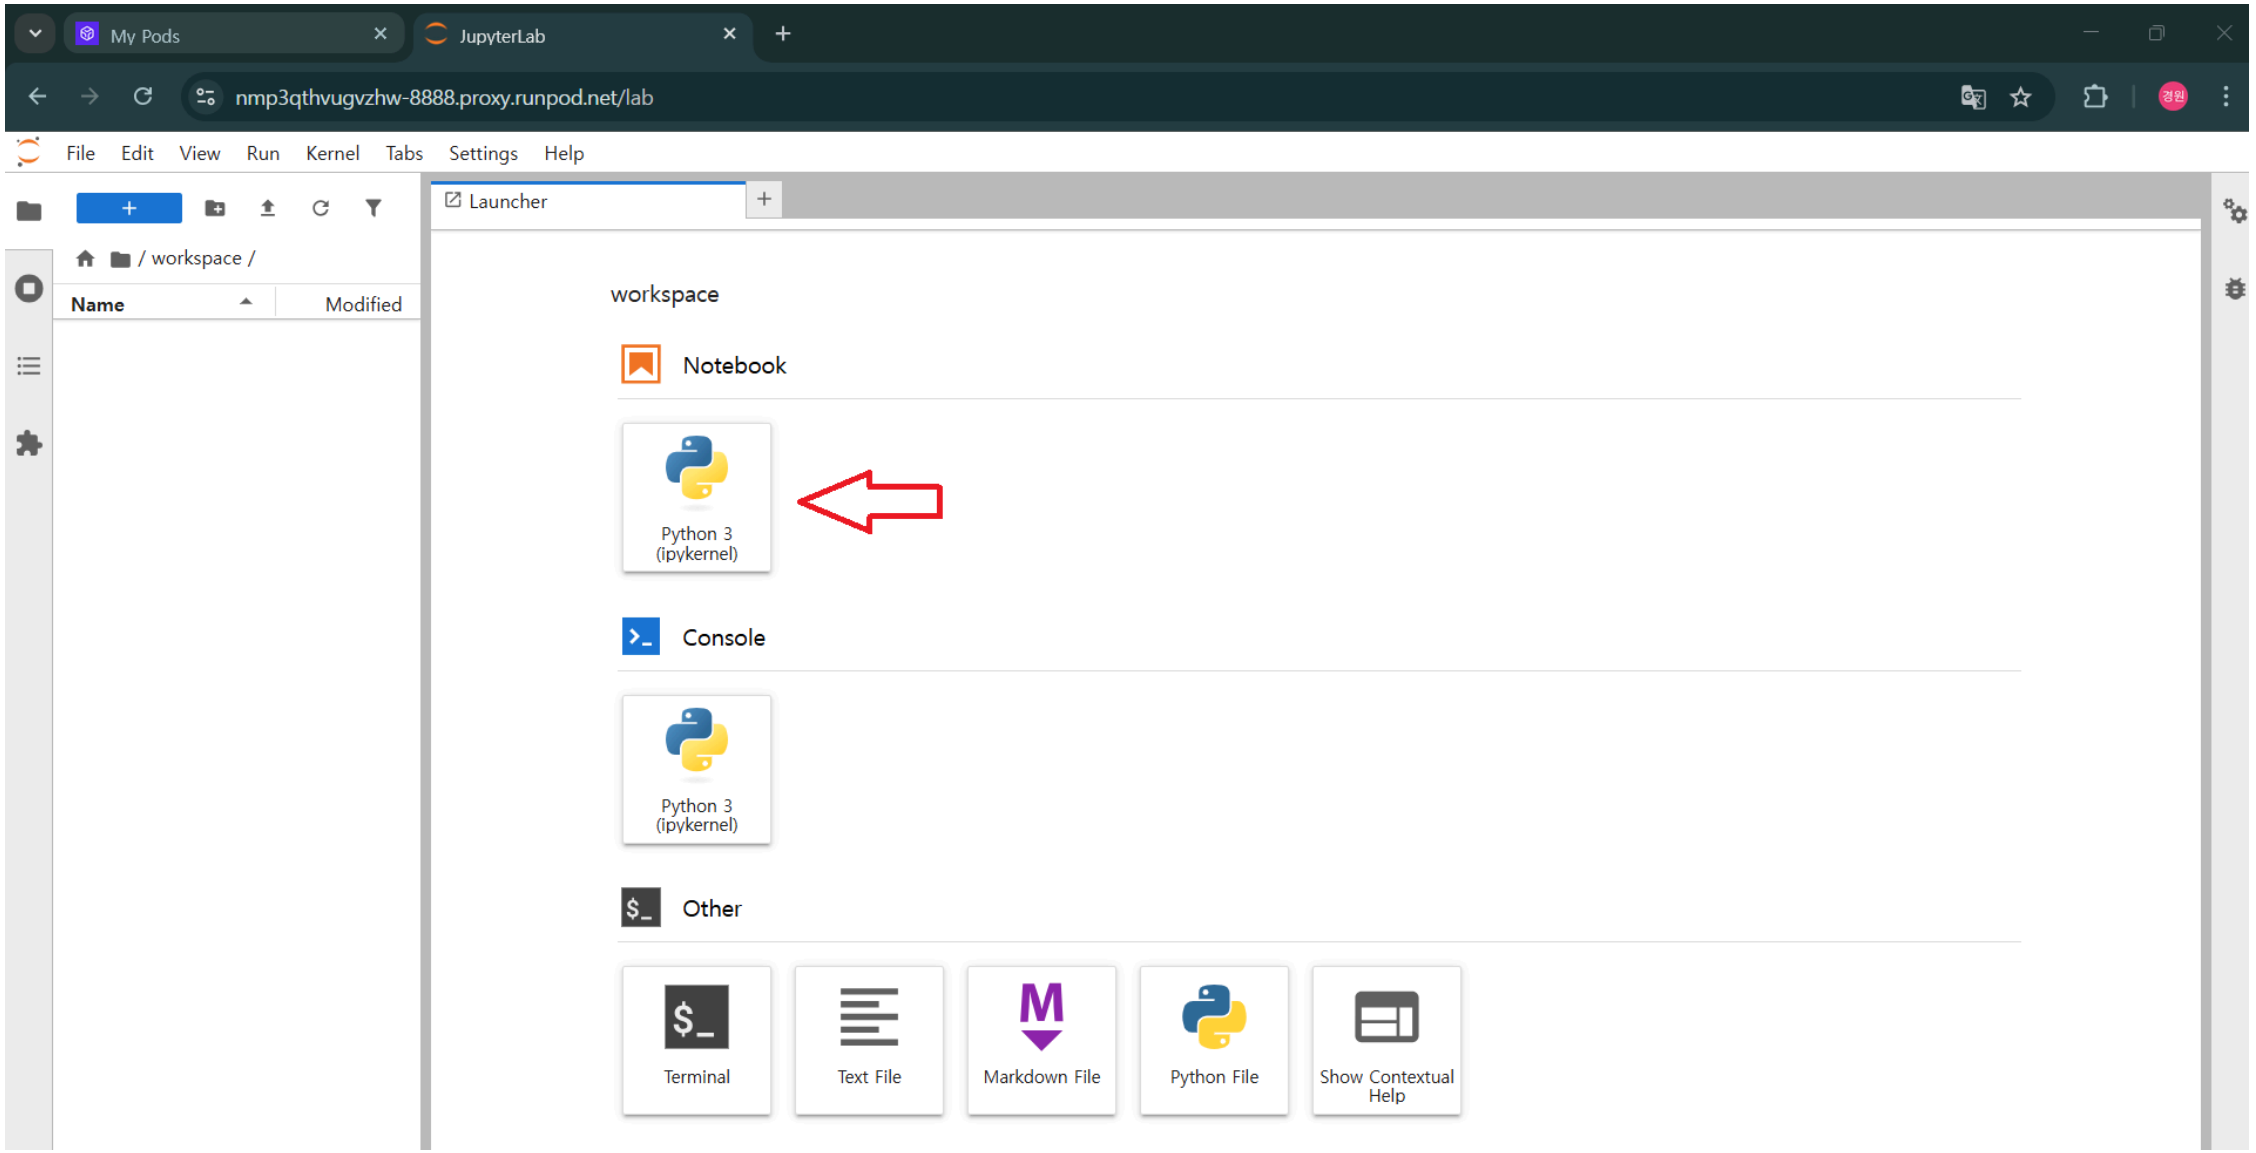

Looking for multi-year savings plans? Contact sales
Encrypt volume
SSH terminal access
Start Jupyter notebook
Storage configuration
Container disk
Temporary storage that will be erased when the Pod is stopped.
– 30 GB +
Volume disk
Persistent storage mounted to /workspace tied to the Pod's lifecycle.
- Will be deleted when Pod is terminated
- Cannot be accessed by other Pods or Endpoints
$0.10/GB/mo when running, $0.20/GB/mo when stopped
Network volume
$ Save up to 75%
Persistent storage mounted to /workspace that is independent from the Pod's lifecycle.
- Will not be deleted when Pod is terminated
- Can be mounted to multiple Pods & Endpoints
$0.07/GB/mo (under 1TB) or $0.05/GB/mo (over 1TB)
Volume disk
Persistent storage mounted to /workspace that will be erased when the Pod is terminated.
– 50 GB +
Pricing summary
GPU cost $0.89 / hr
Running Pod disk cost $0.011 / hr
Stopped Pod disk cost $0.014 / hr
Pod summary
1x RTX 5090 (32 GB VRAM)
60 GB RAM • 12 vCPU
Total disk 80 GB
Deploy On-Demand

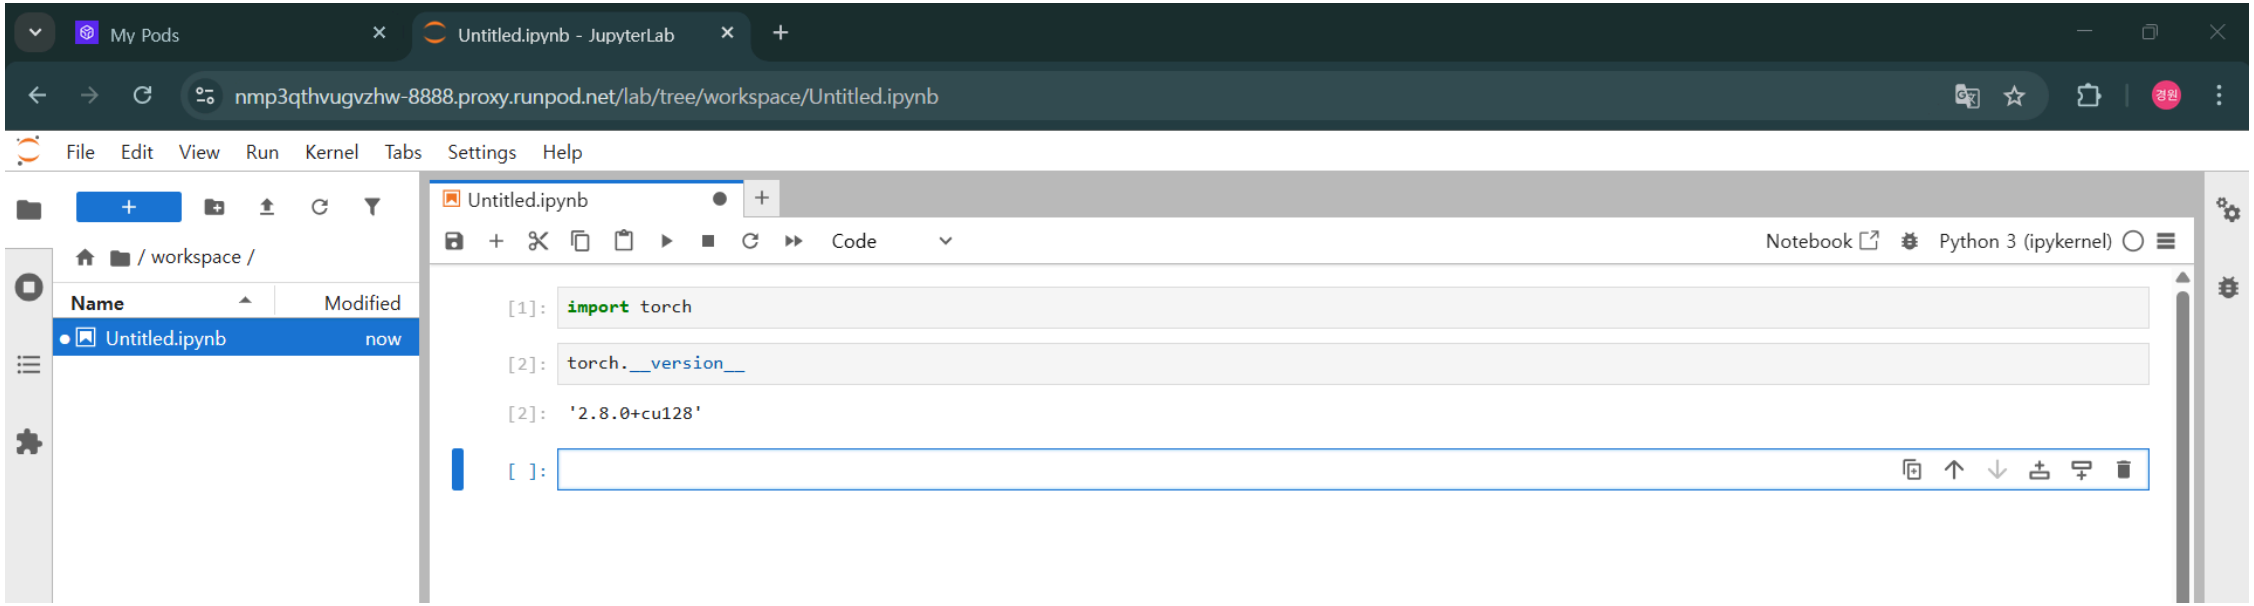

Pods
Deploy
Name
Utilization
Memory
Disk
test-pod
nmp3qthvugvzhw
10 per page
Pods
test-pod
ID
nmp3qthvugvzhw
Stop
Cloud Sync
Create savings plan
Connect
Details
Telemetry
Logs
Template Readme

단계3: Pod 접속 및 사용

> 요금 = 시간당 가격 × 사용한 시간

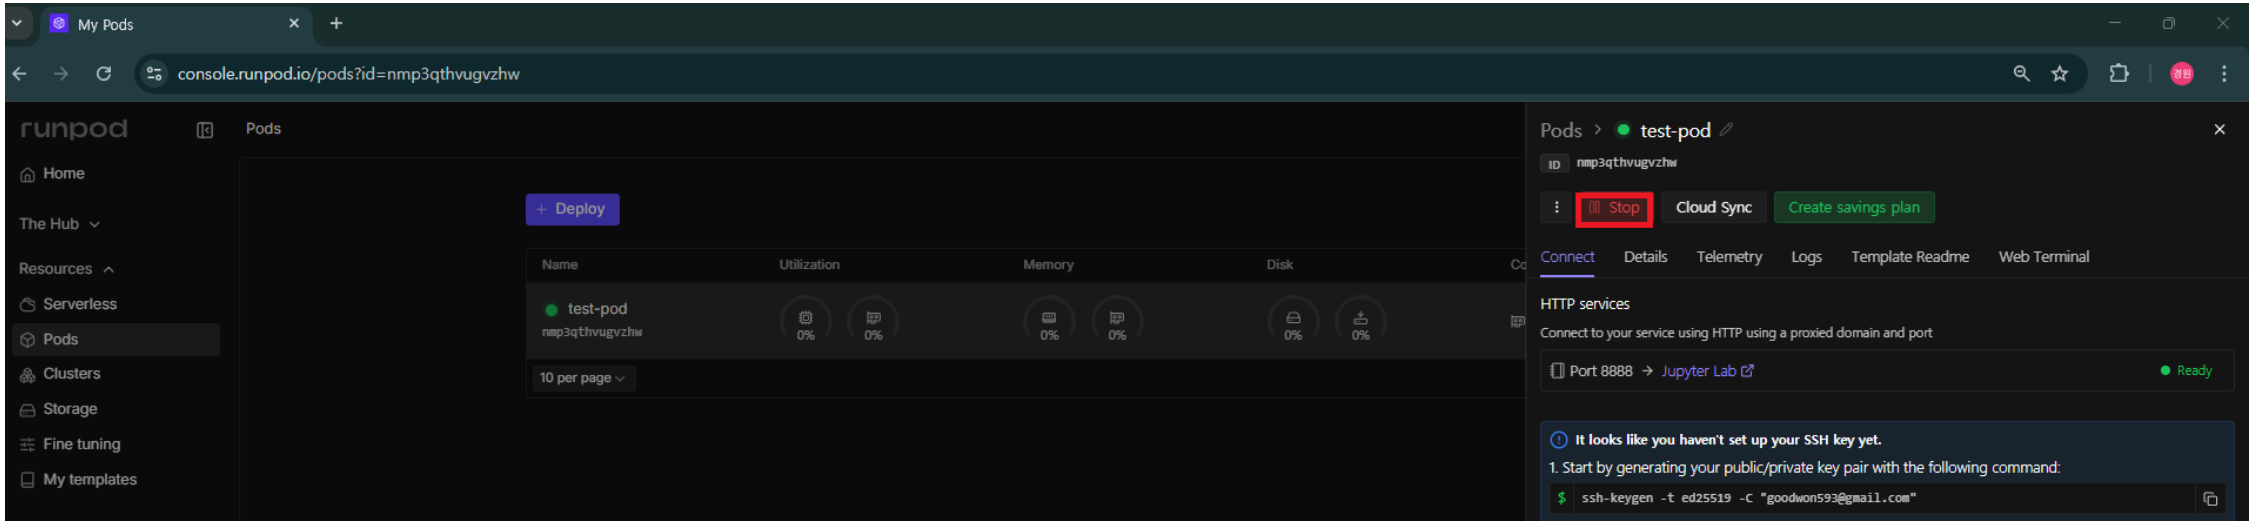



My Pods
JupyterLab
nmp3qthvugvzhw-8888.proxy.runpod.net/lab
File Edit View Run Kernel Tabs Settings Help
/ workspace /
Name
Modified
Launcher
workspace
Notebook
Python 3 (ipykernel)
Console
Python 3 (ipykernel)
Other
Terminal
Text File
Markdown File
Python File
Show Contextual Help


My Pods
Untitled.ipynb - JupyterLab
nmp3qthvugvzhw-8888.proxy.runpod.net/lab/tree/workspace/Untitled.ipynb
File Edit View Run Kernel Tabs Settings Help
/ workspace /
Name
Modified
Untitled.ipynb
now
Untitled.ipynb
Code
Notebook
Python 3 (ipykernel)
[1]: import torch
[2]: torch.__version__
[2]: '2.8.0+cu128'
[ ]:

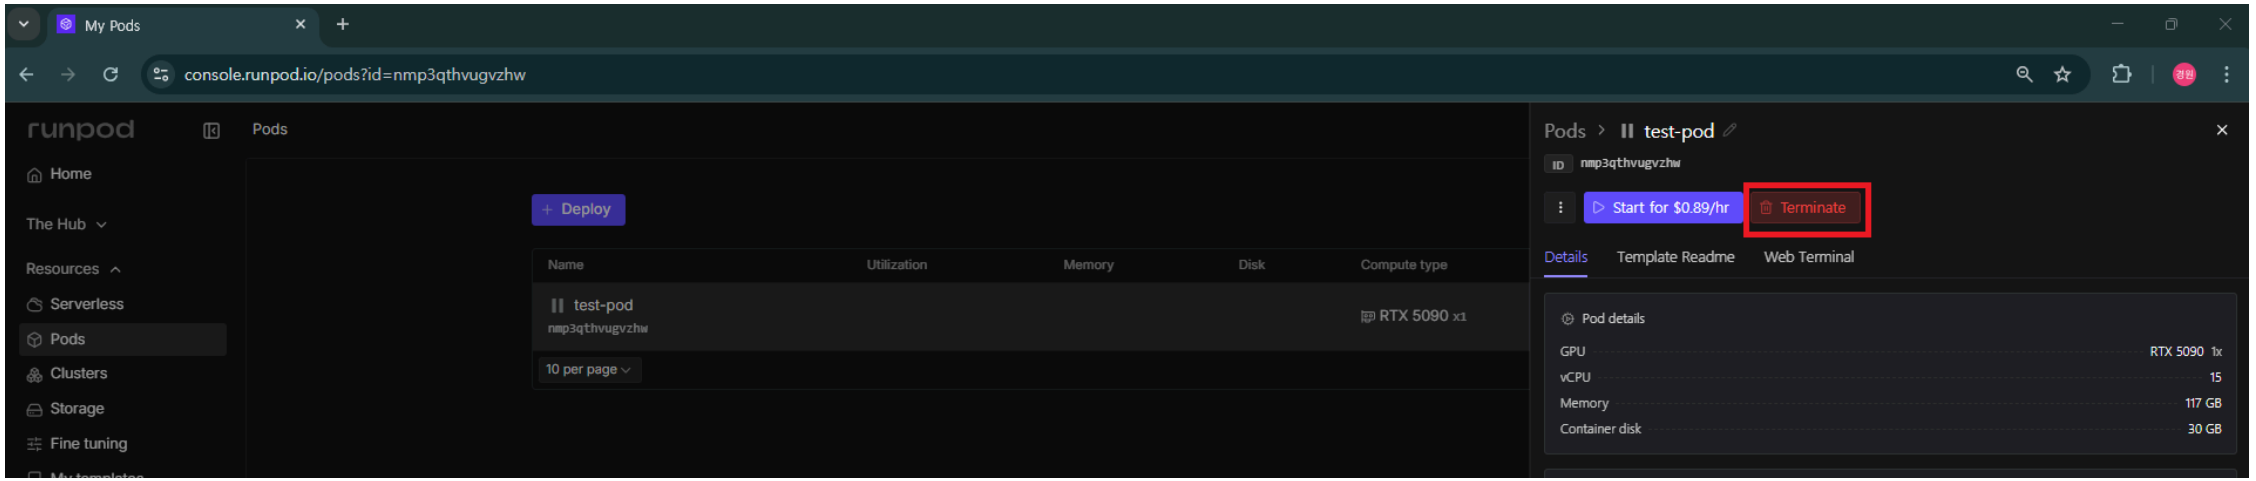
단계4: Pod 멈추기

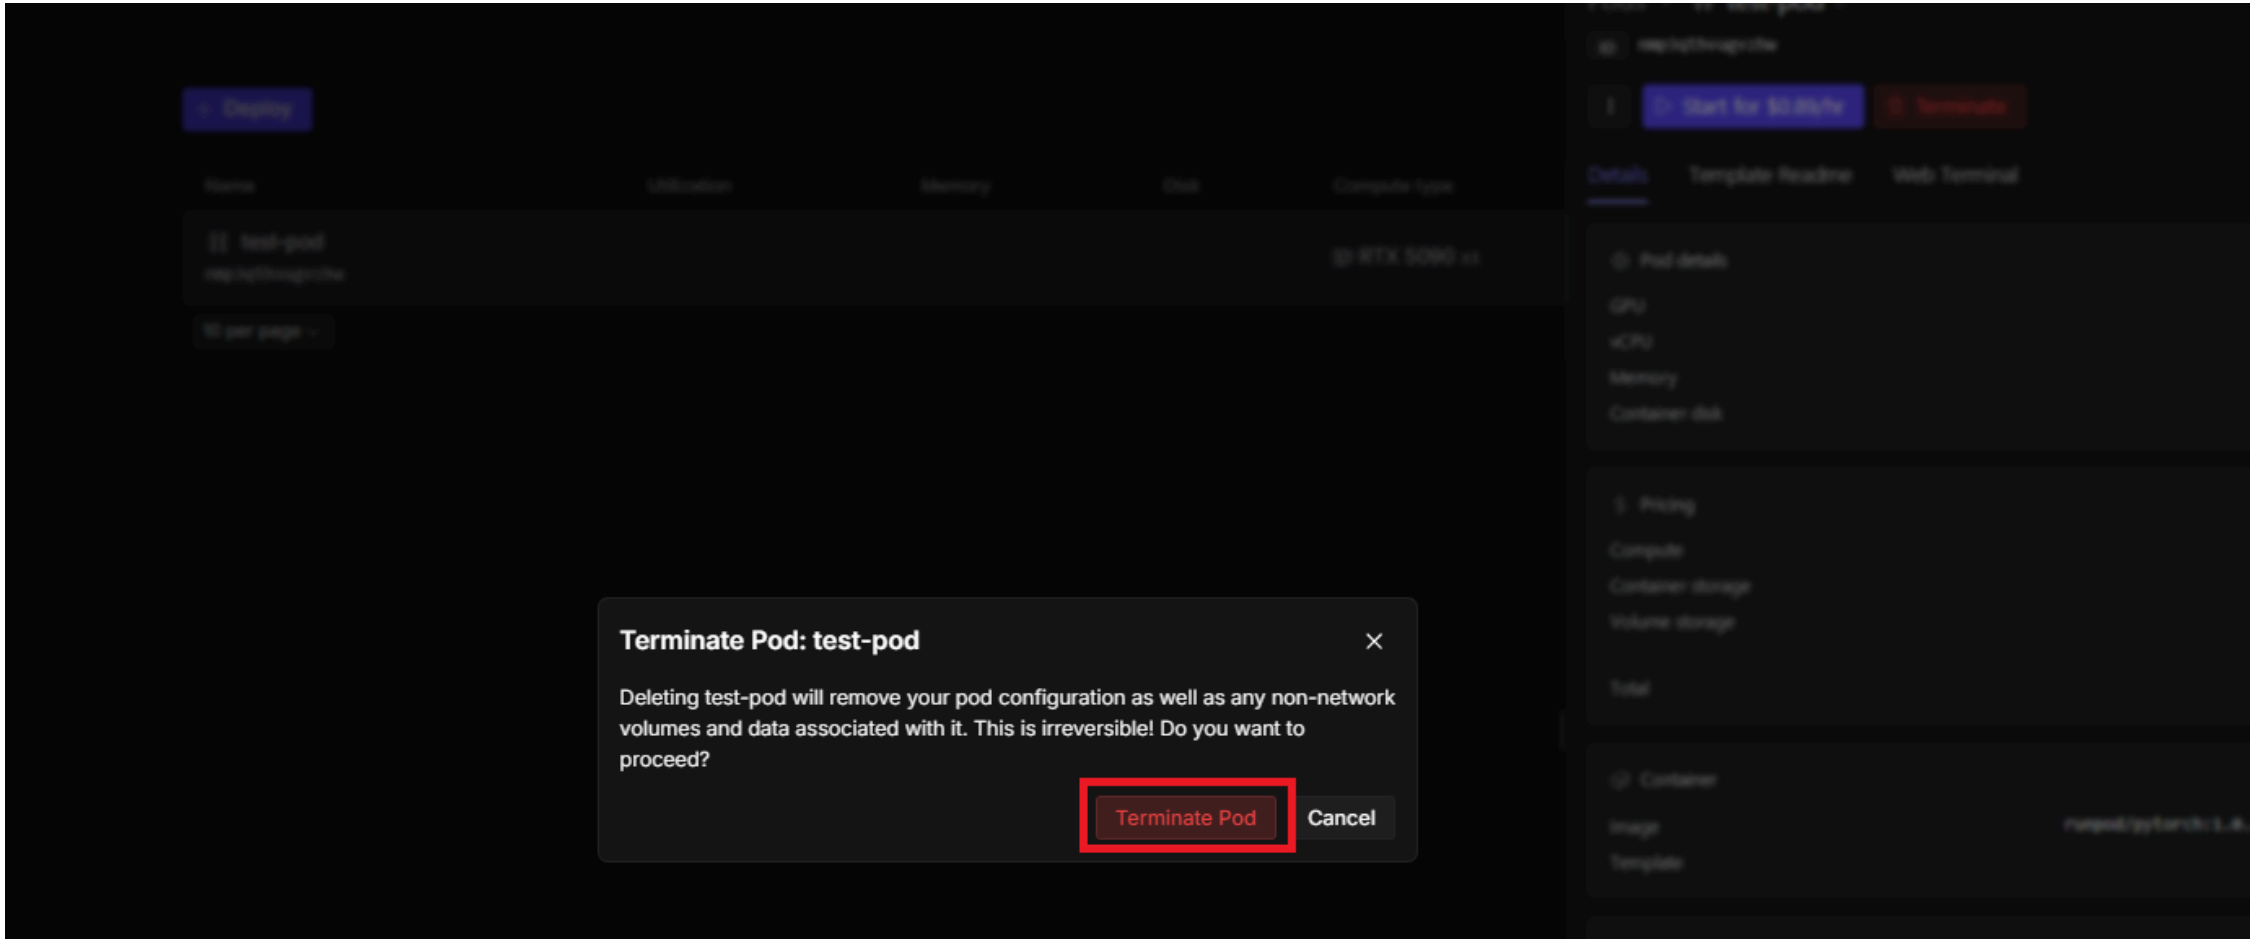
> Pod **중지(Stop)** — 스토리지 요금만 과금



단계5: Pod 삭제하기

> Pod **삭제(Terminate)** — 요금 0원




Terminate Pod: test-pod
Deleting test-pod will remove your pod configuration as well as any non-network volumes and data associated with it. This is irreversible! Do you want to proceed?
Terminate Pod
Cancel