vLLM

> LLM(대형 언어 모델)을 **빠르고 효율적으로 실행**해주는 추론 엔진

쉽게 비유하면:

- LLM = 엄청 똑똑한 요리사
- vLLM = 요리사가 최대한 빠르게 일할 수 있게 해주는 주방 시스템

vLLM의 핵심 기능

기능	설명
PagedAttention	GPU 메모리를 효율적으로 관리해서 더 많은 요청을 동시에 처리
Continuous Batching	요청이 들어오는 즉시 처리 (기다리지 않음)
OpenAI 호환 API	ChatGPT API와 동일한 형식 → 코드 변경 최소화

vLLM 없이 vs. vLLM 있을 때

vLLM 없이

```
요청 1 처리 → 완료 → 요청 2 처리 → 완료 → 요청 3 처리...
(한 번에 하나씩)
```

vLLM 있을 때

```
요청 1, 2, 3 → 동시에 묶어서 처리 → 훨씬 빠름
(여러 개를 한꺼번에)
```

RunPod Serverless with vLLM

> RunPod Serverless는 vLLM을 공식 지원함.

RunPod Serverless 종류

	Flex Workers	Active Workers
상태	요청 시 켜짐, 유휴 시 꺼짐	항상 켜져 있음
Cold Start	**있음**	**없음**
비용	실행 시간만 과금	유휴 시에도 과금
할인	없음	20~30% 할인
기본값	Max Workers 수만큼	0

> Cold Start란?
> 요청이 들어왔는데 실행 중인 Worker가 없을 때, GPU를 새로 띄우는 데 걸리는 시간

Cold Start의 실서비스 문제점

1. 응답 시간이 예측 불가능하다
    - 같은 API인데 호출할 때마다 응답 시간이 달라짐
2. 사용자 경험(UX)이 망가진다
    - SLA(응답 시간 보장) 맞추기 불가능
3. 타임아웃 에러가 발생한다
    - 클라이언트 측 타임아웃 설정보다 Cold Start가 더 오래 걸리면 에러

vLLM에서 Cold Start가 특히 심한 이유

- LLM은 모델 파일 자체가 엄청 크기 때문
- 아무리 vLLM으로 추론을 빠르게 최적화해도, Cold Start가 있으면 첫 응답은 무조건 느림

모델	모델 크기	예상 Cold Start
Llama 3 8B	~16GB	1~2분
Llama 3 70B	~140GB	5~10분
Mistral 7B	~14GB	1~2분

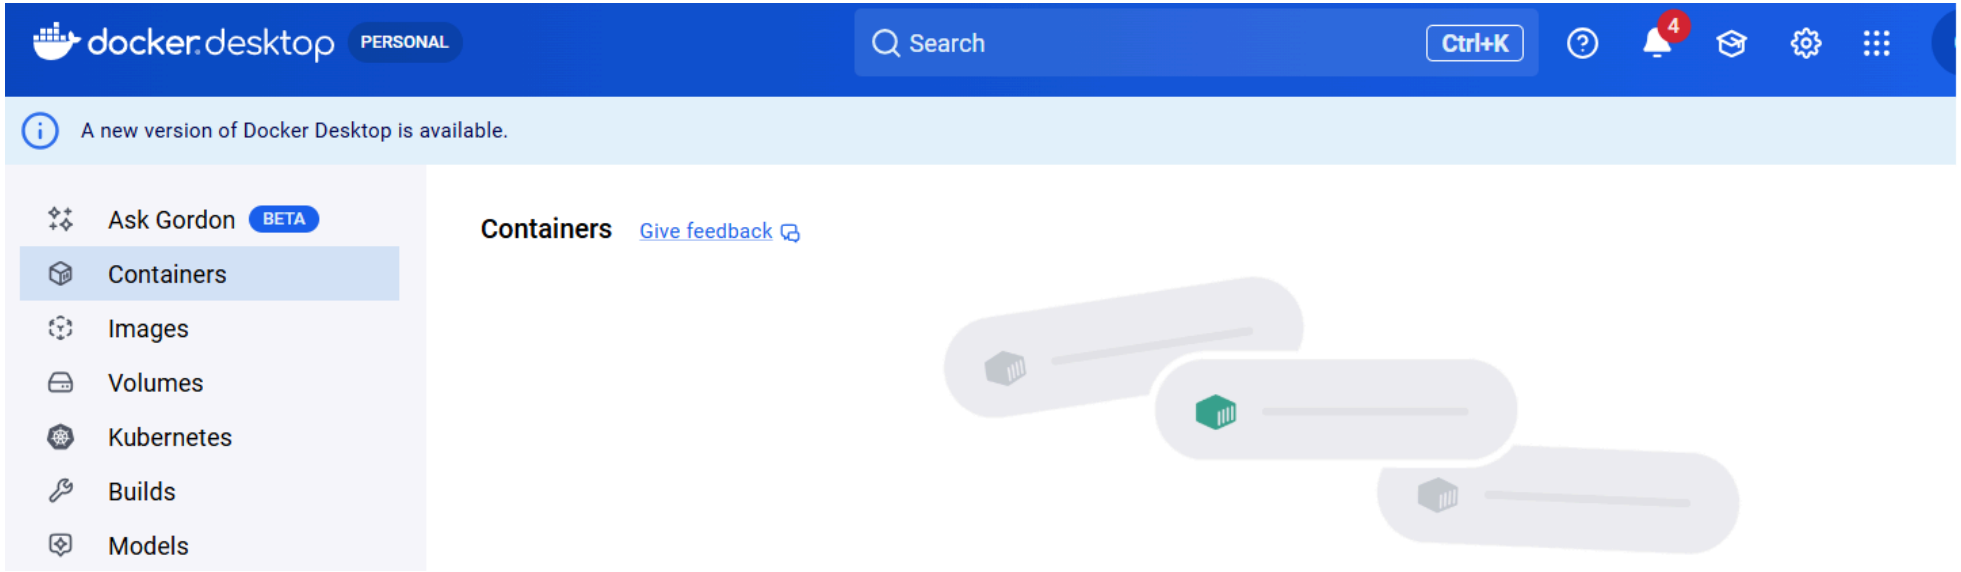
해결책: Active Workers

- Worker를 항상 켜두는 설정 → Cold Start 완전히 제거

예제: Active Workers with vLLM

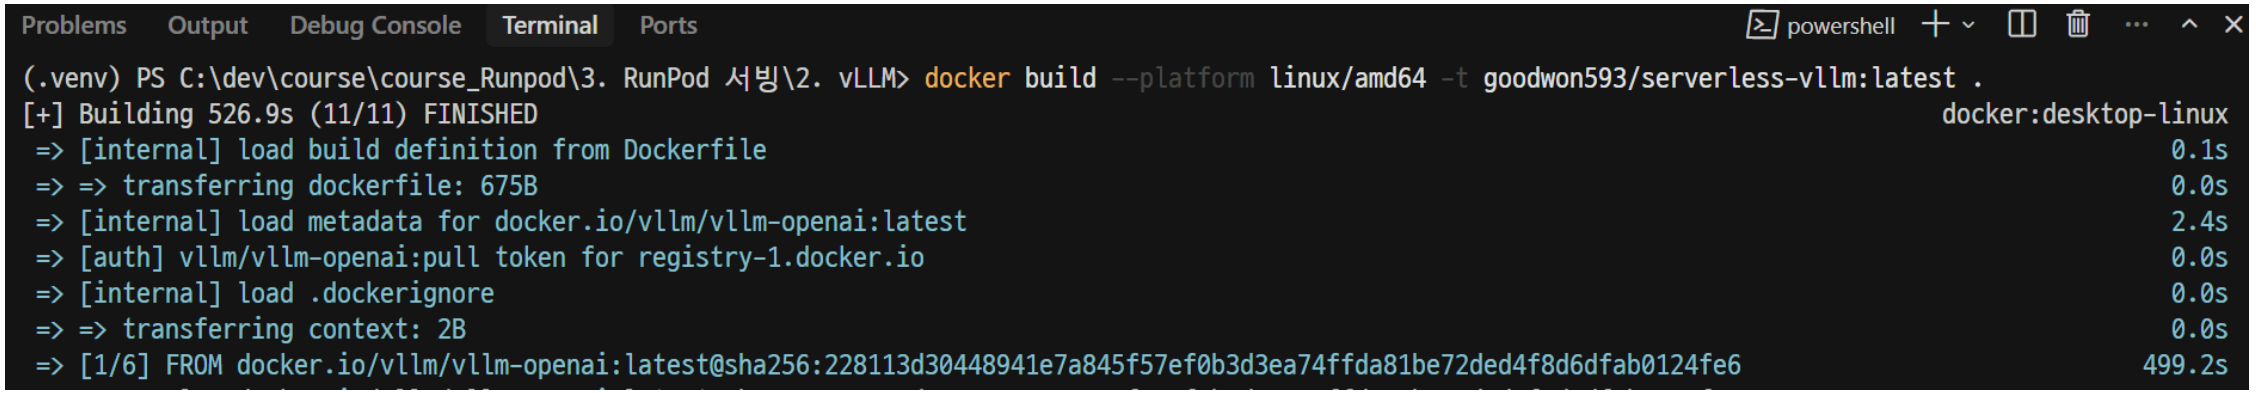
1. Docker

단계1: Docker Server 실행 및 로그인

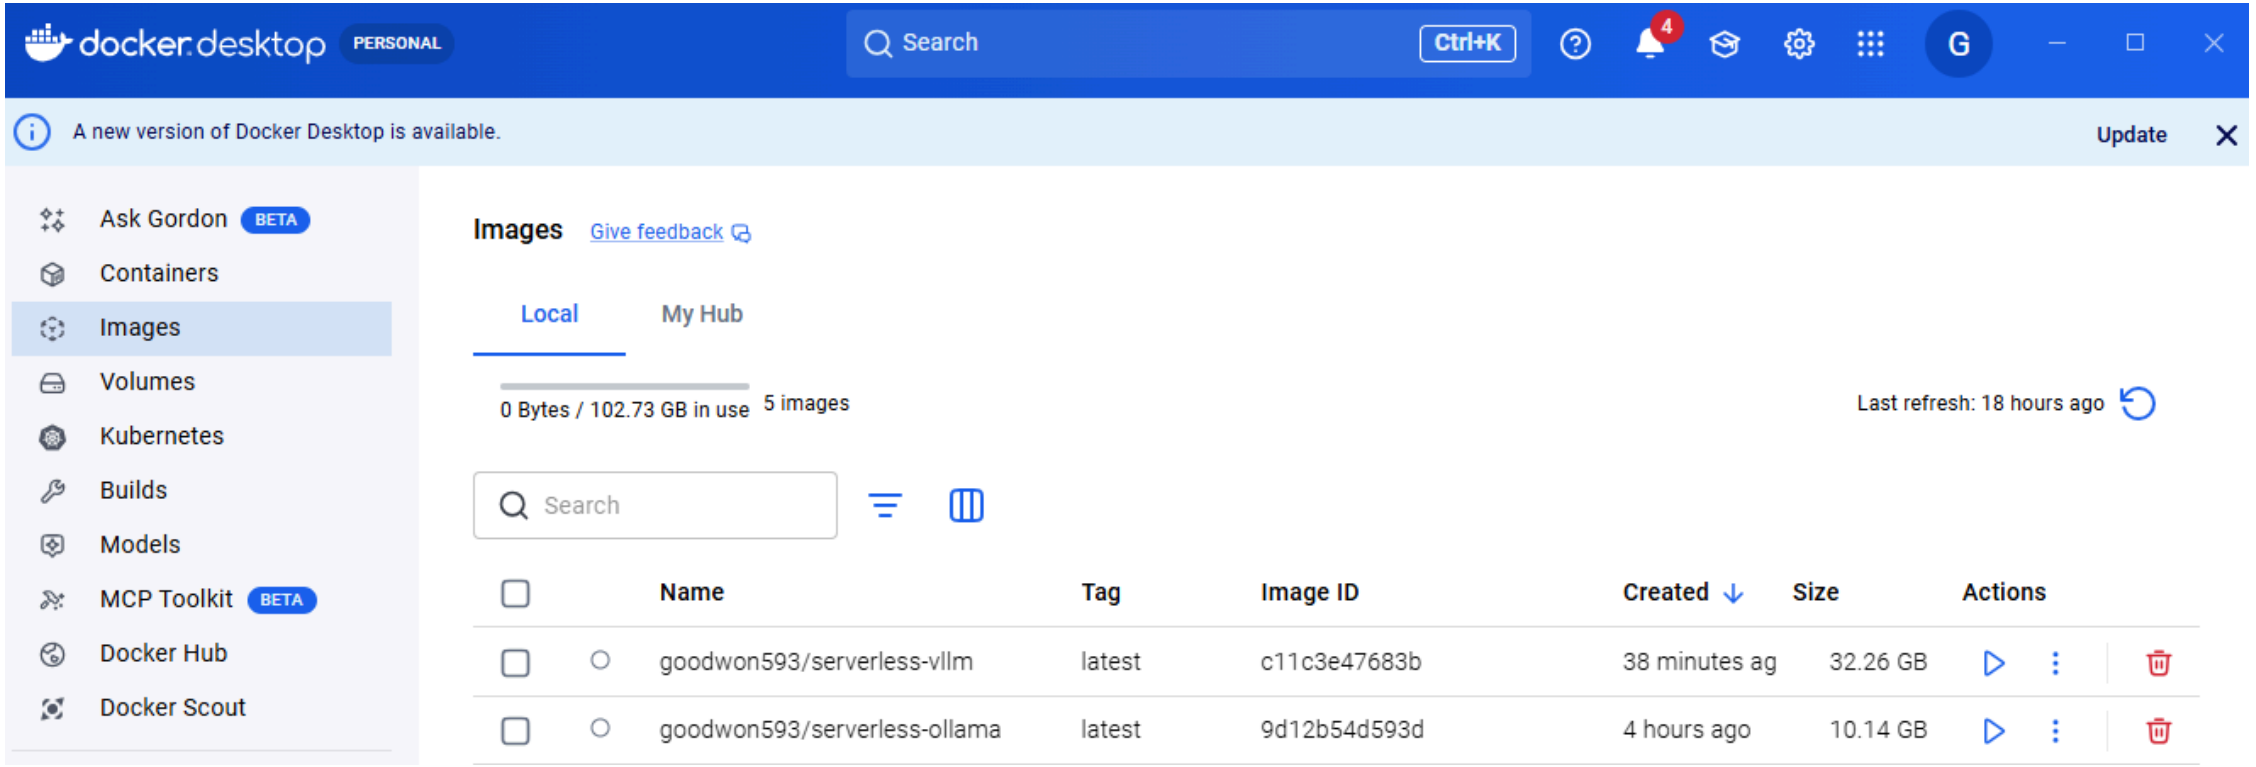


단계2: Docker Image 생성

```
# 도커파일이 있는 폴더에서 실행
docker build --platform linux/amd64 -t [YOUR_USERNAME]/serverless-vllm:latest .
```

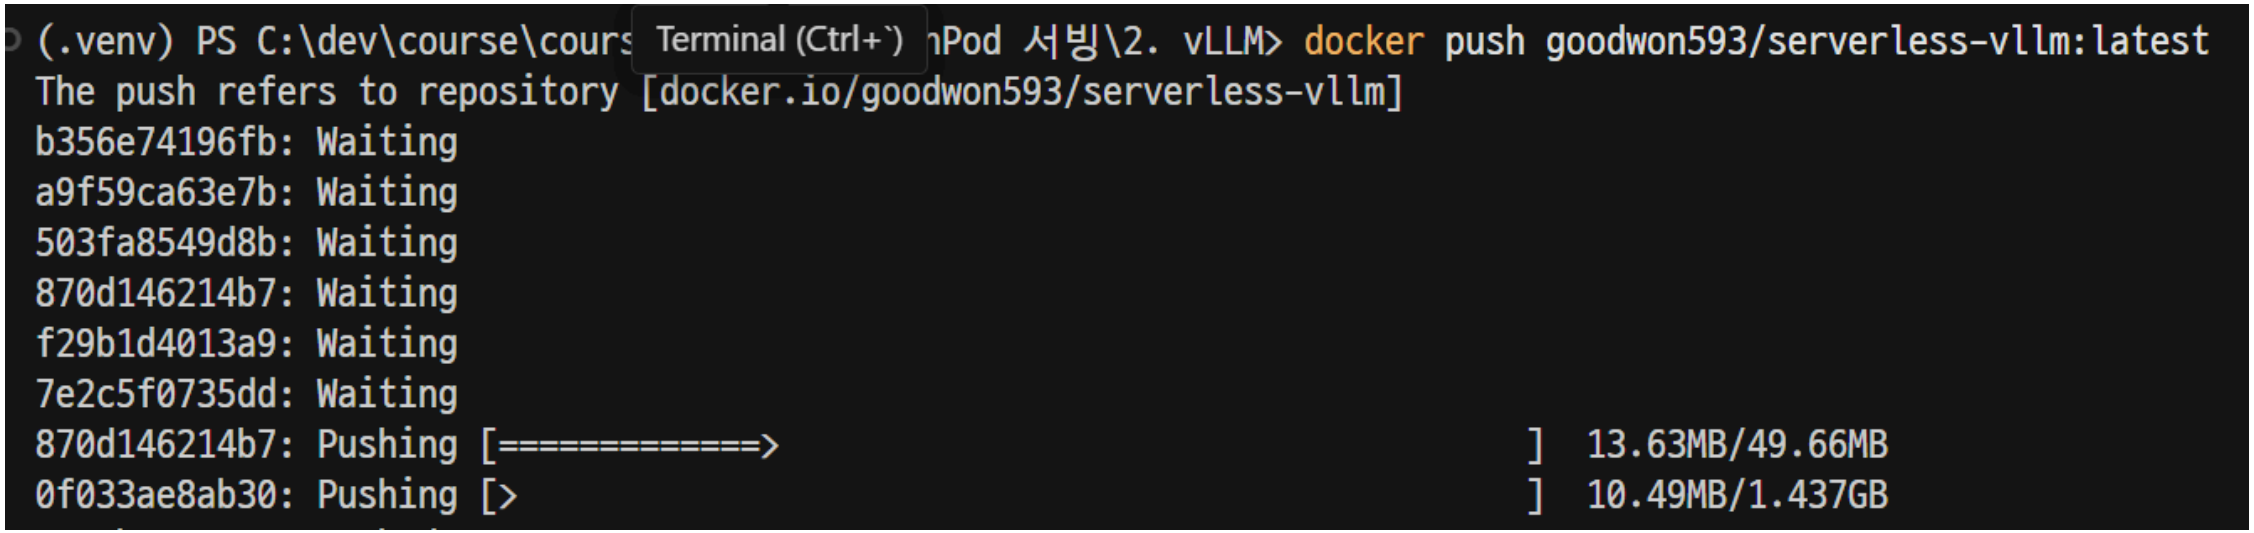


단계3: 생성된 Docker Image 확인



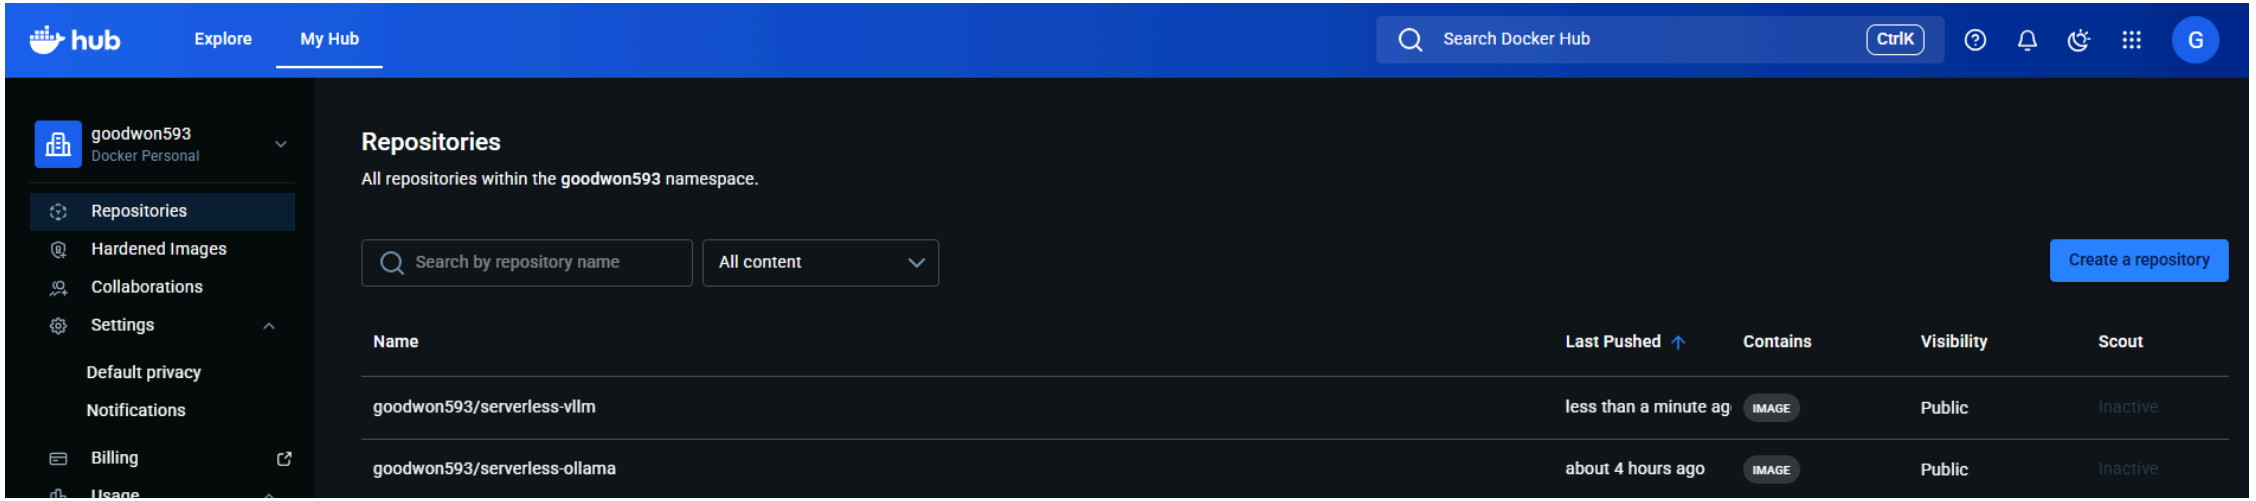
단계4: Docker Hub 배포

```
docker push [YOUR_USERNAME]/serverless-vllm:latest
```



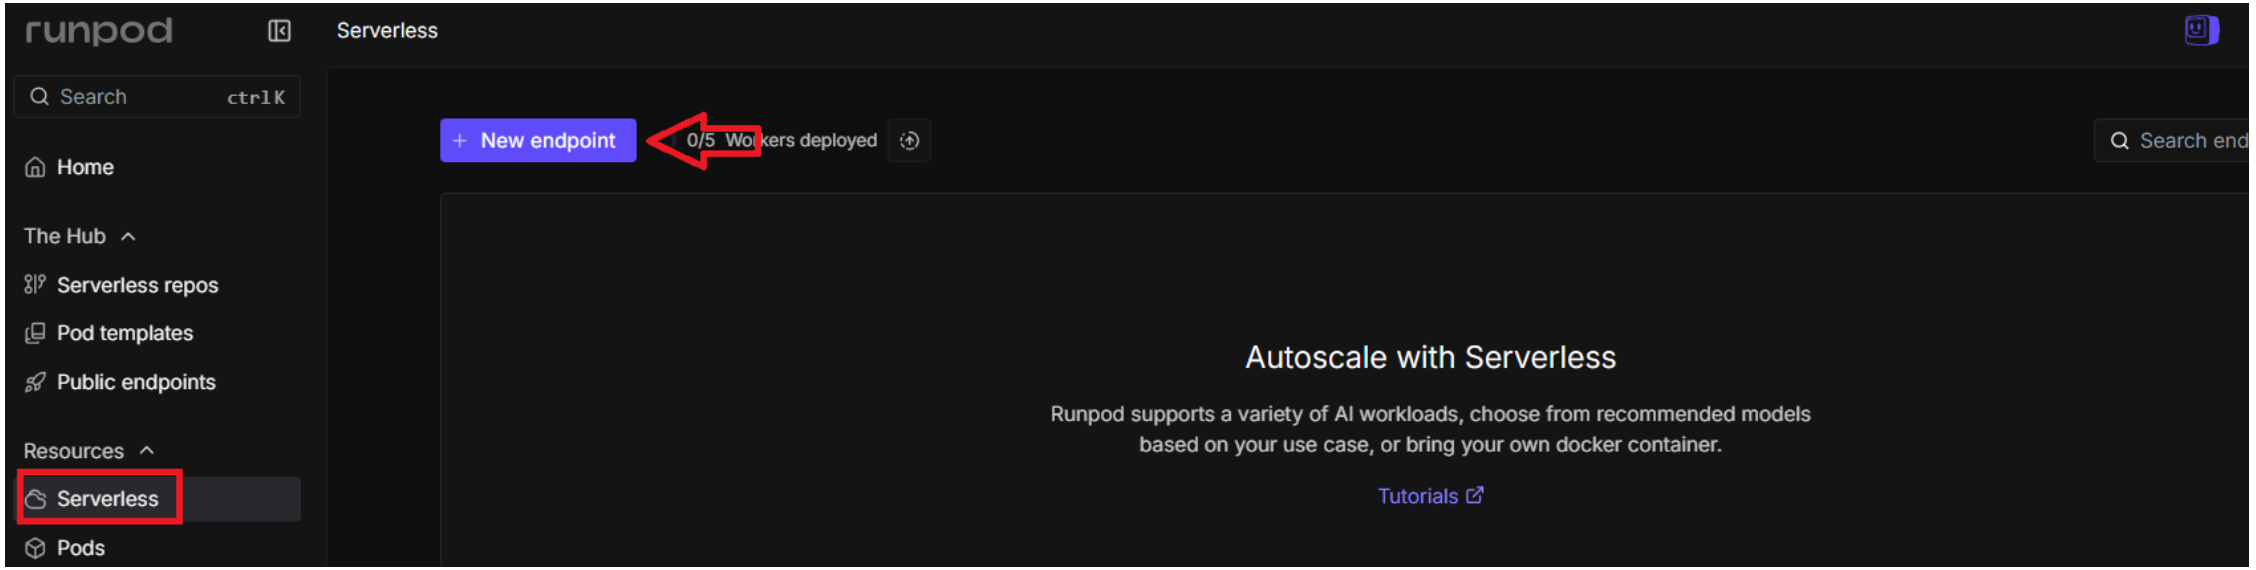
단계5: Docker Hub

> 결과 확인

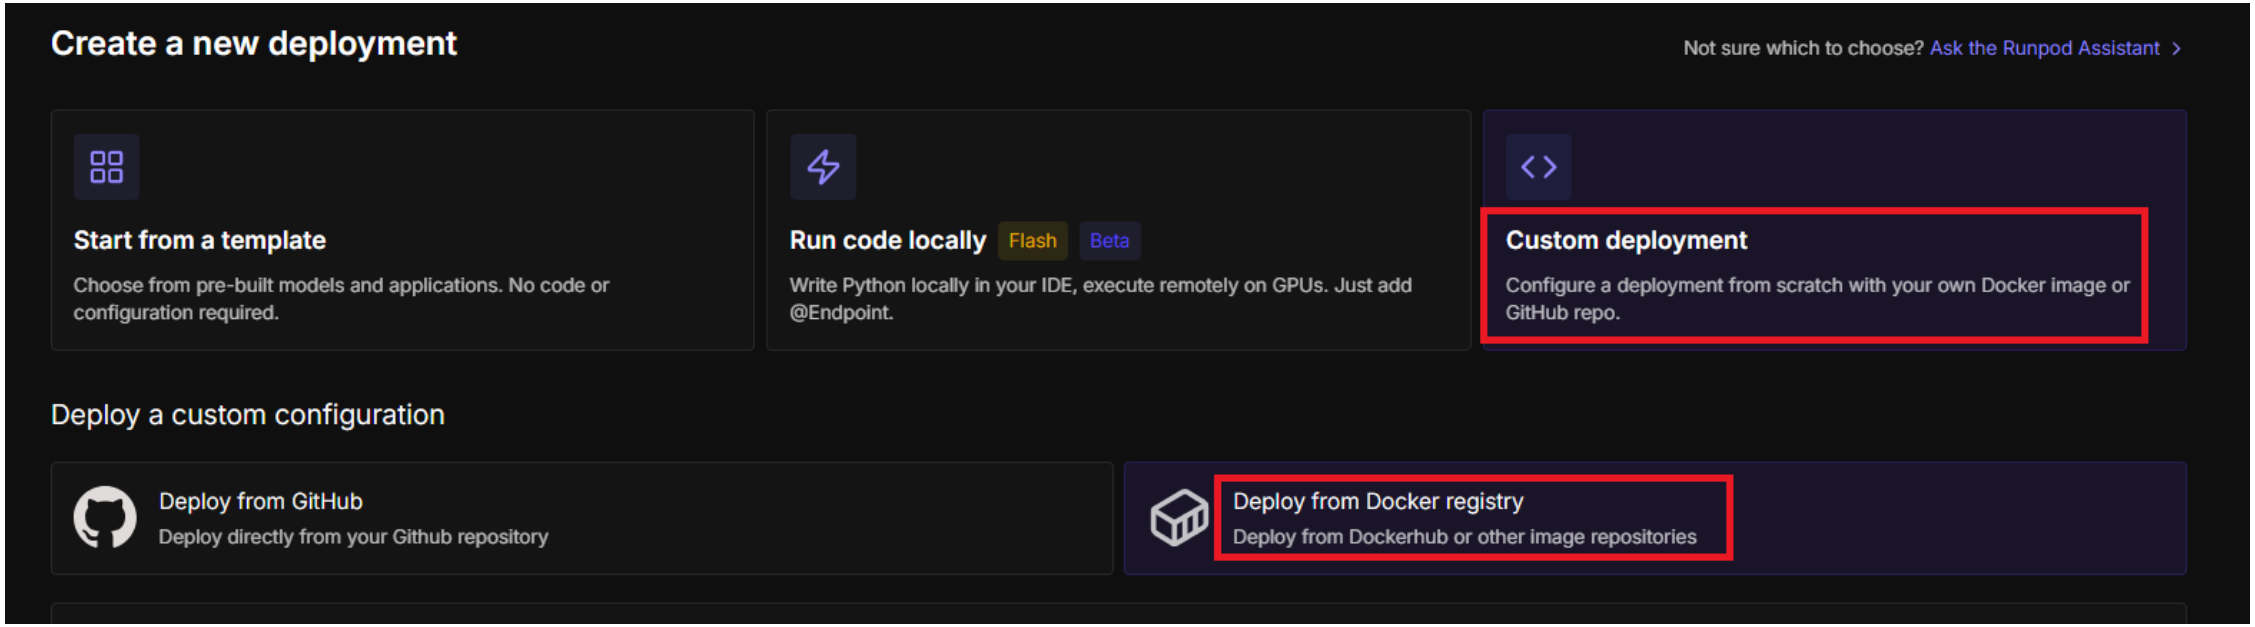


2. Runpod's Serverless(Active Workers)

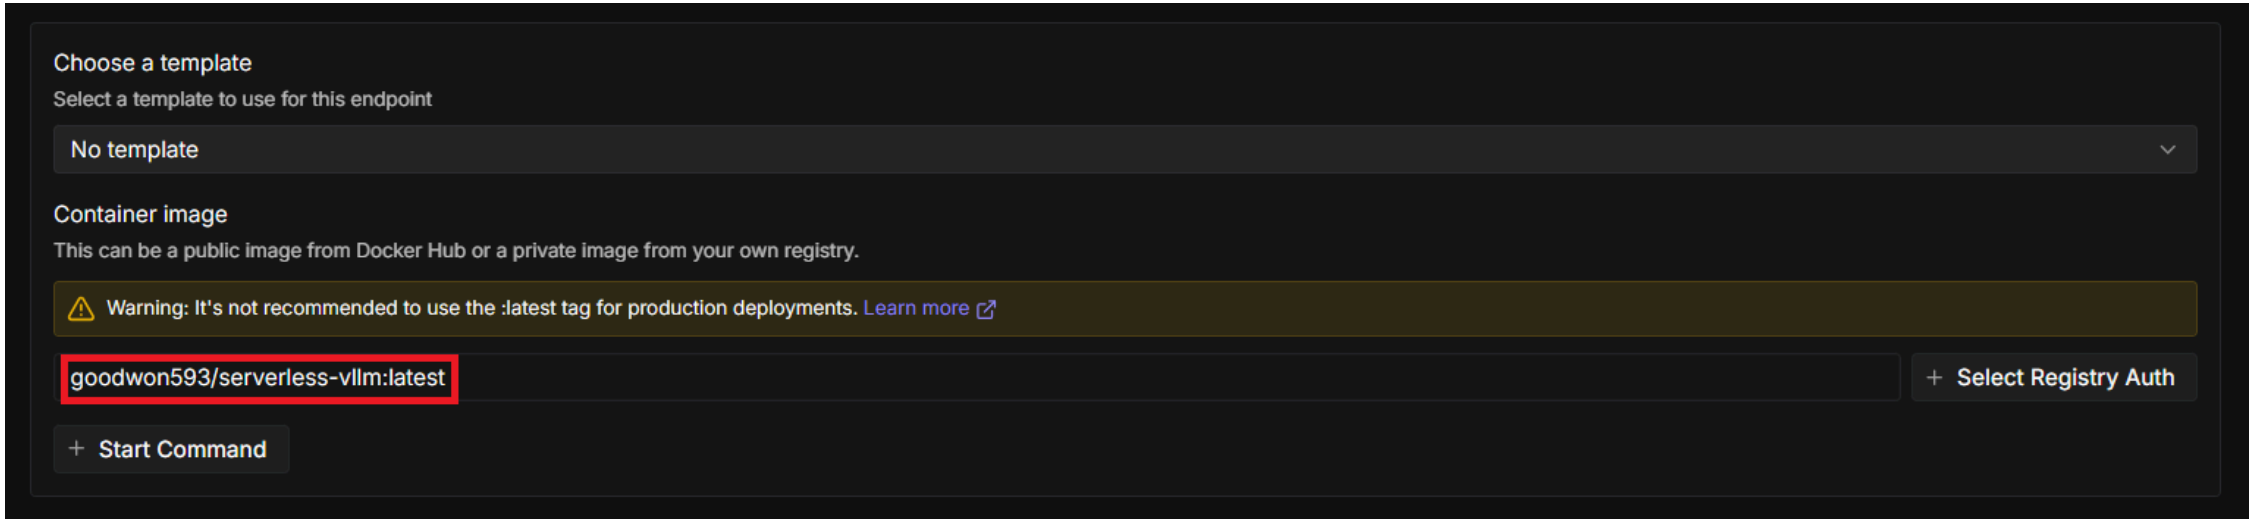
단계1: Serverless > Get started



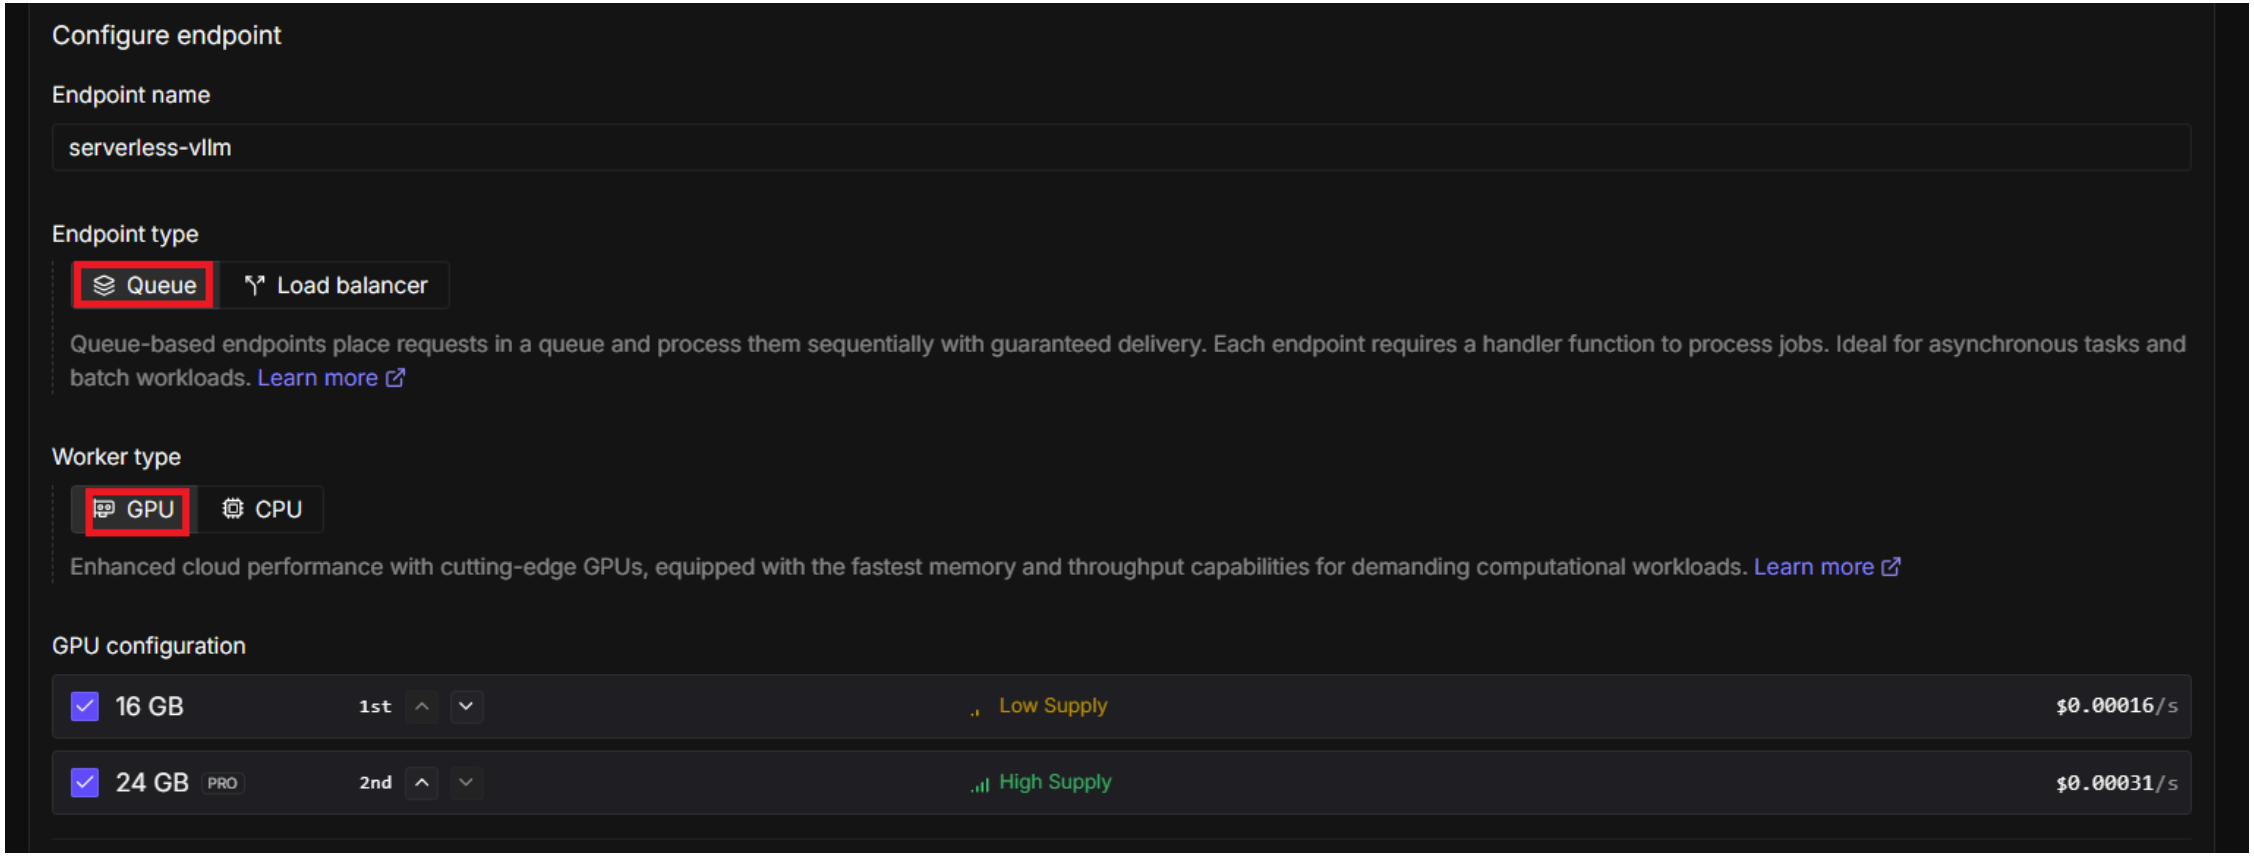
단계2: Create a new deployment



Container image

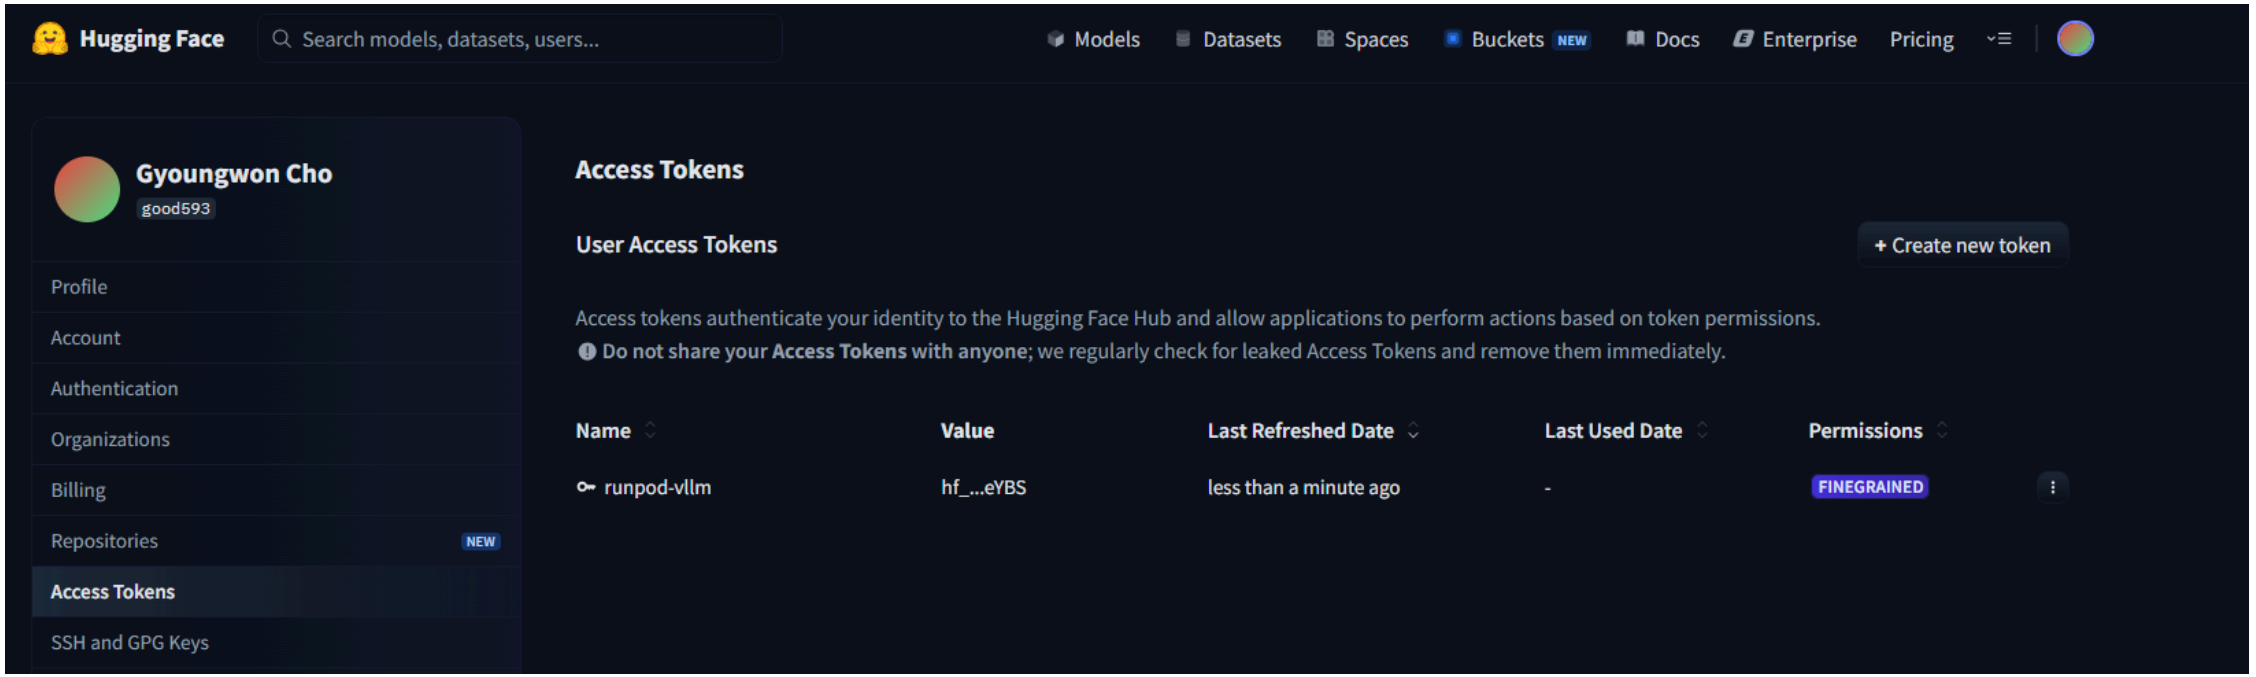


Worker type

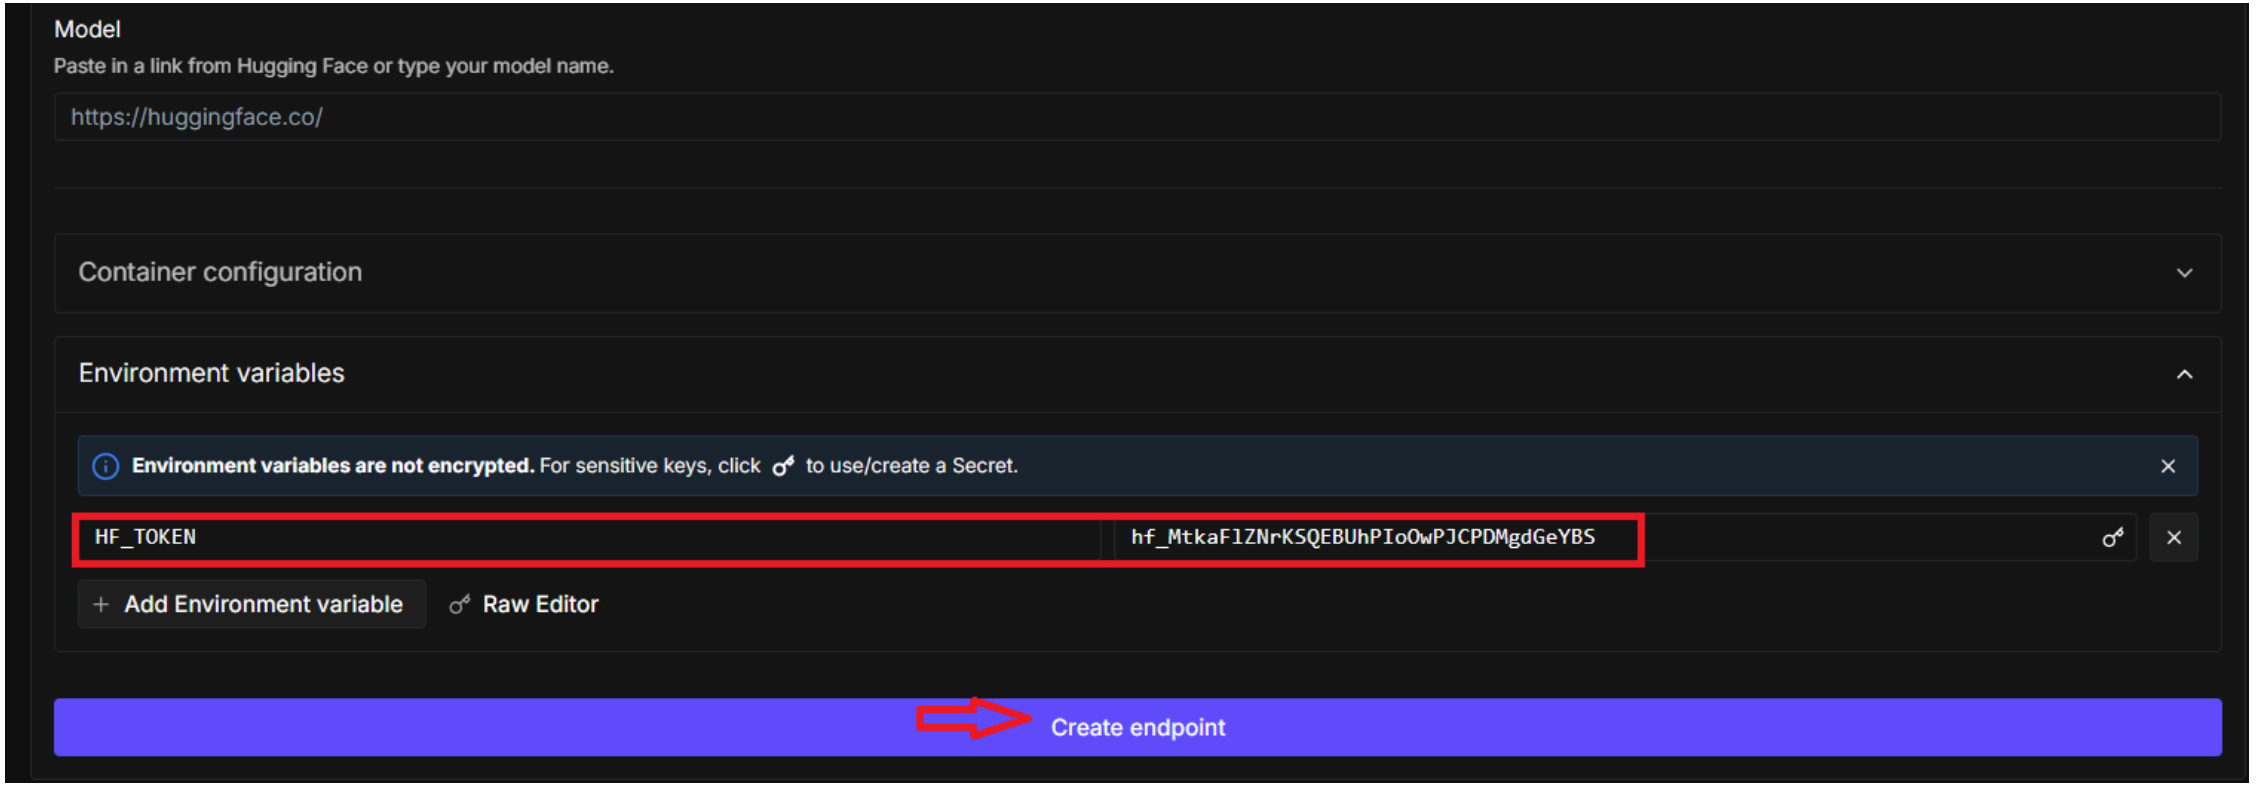

Configure endpoint
Endpoint name
serverless-vllm
Endpoint type
Queue
Load balancer
Queue-based endpoints place requests in a queue and process them sequentially with guaranteed delivery. Each endpoint requires a handler function to process jobs. Ideal for asynchronous tasks and batch workloads. Learn more
Worker type
GPU
CPU
Enhanced cloud performance with cutting-edge GPUs, equipped with the fastest memory and throughput capabilities for demanding computational workloads. Learn more
GPU configuration
16 GB
1st
Low Supply
$0.00016/s
24 GB
PRO
2nd
High Supply
$0.00031/s

단계3: Create endpoint

HuggingFace API 생성

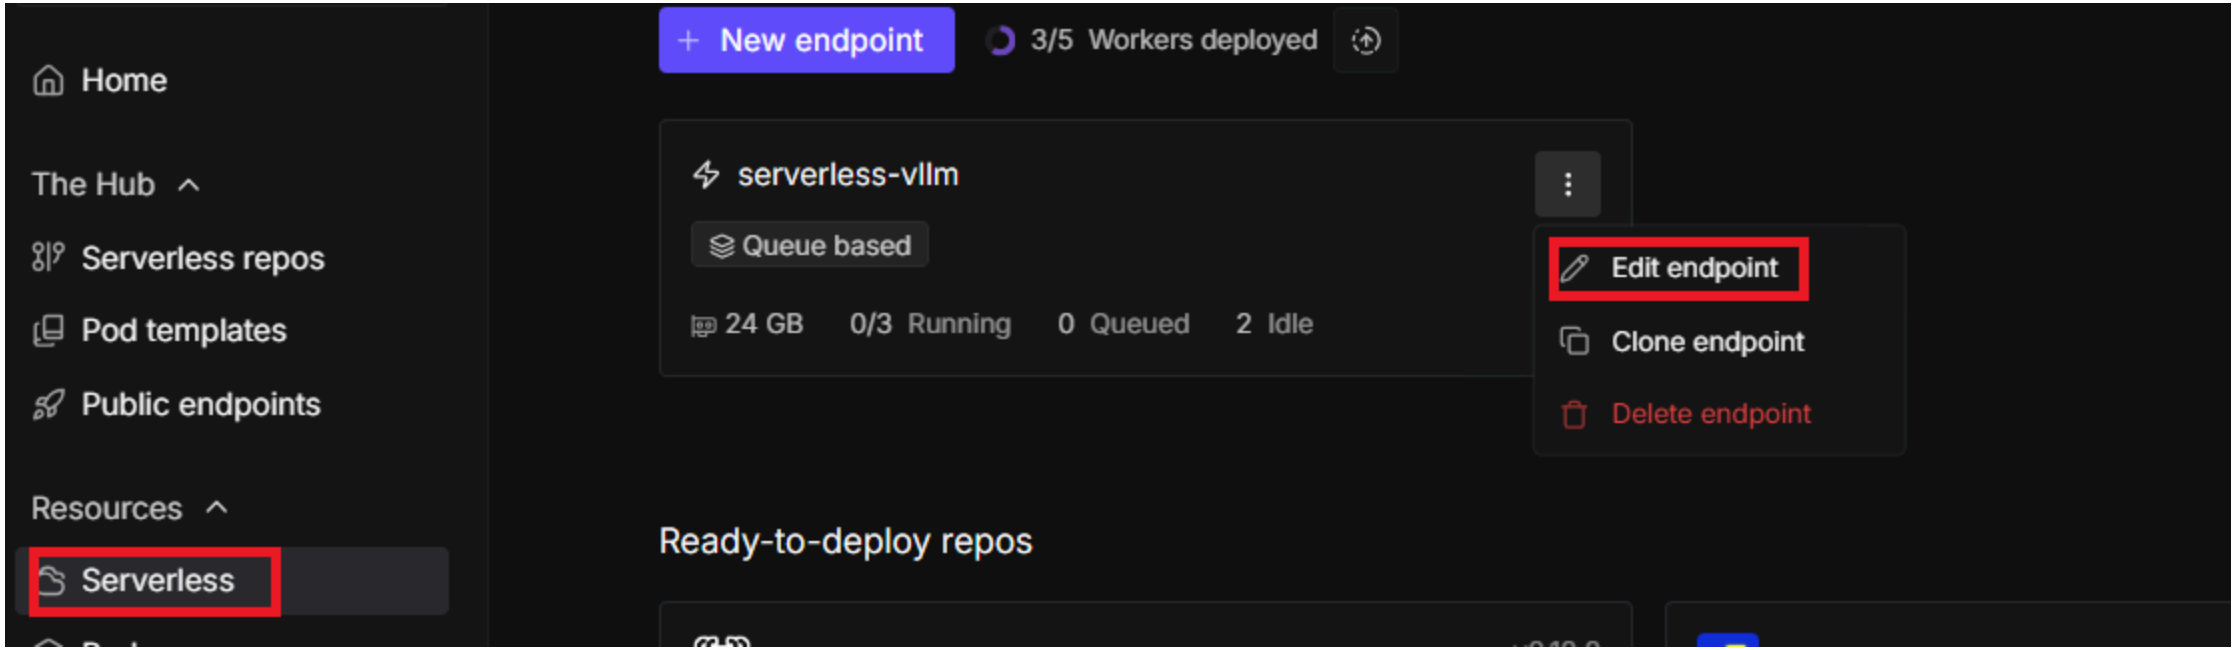


> `HF_TOKEN` : 생성된 HuggingFace API

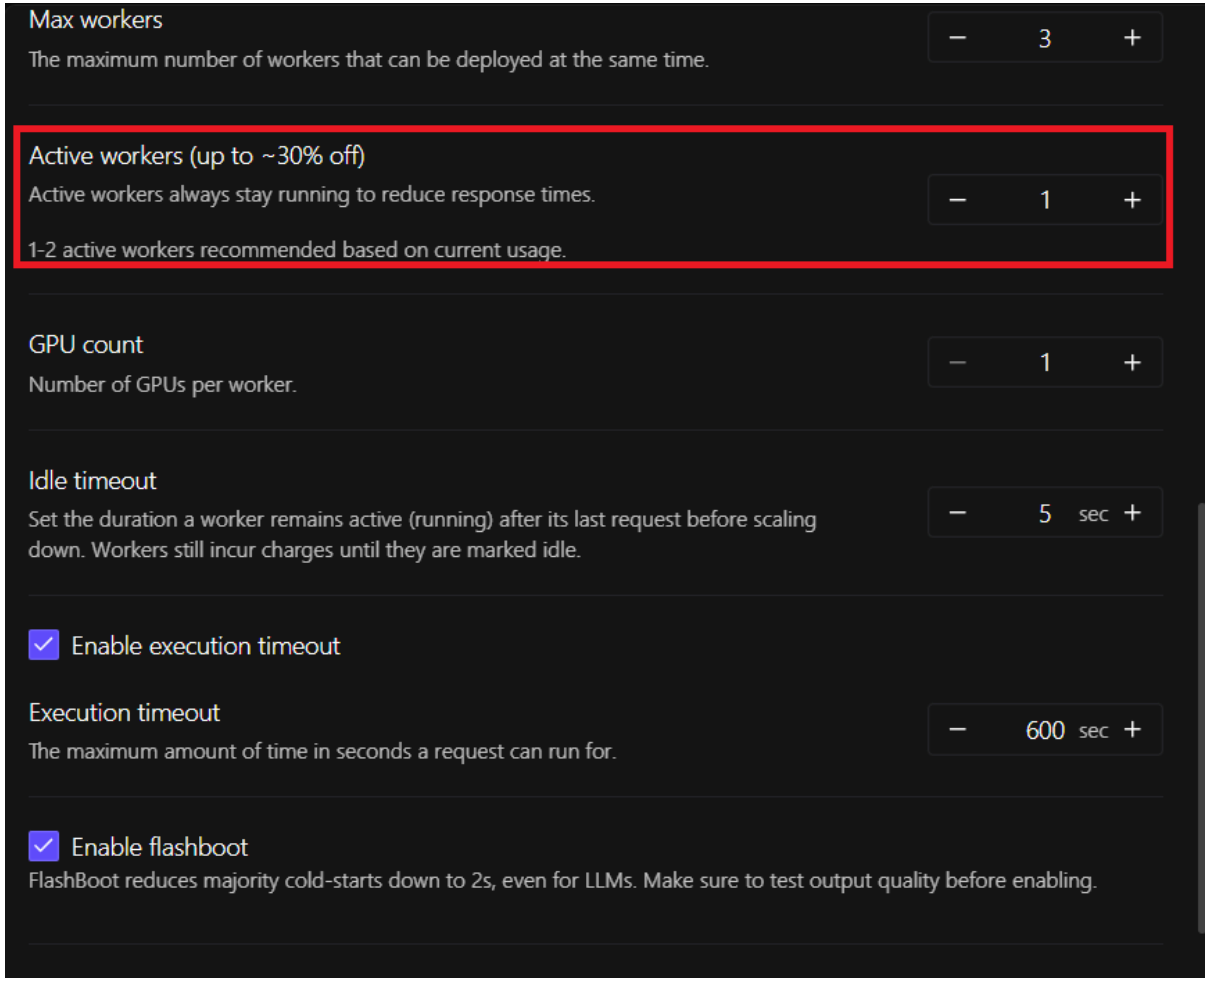


단계4: Active Workers 적용

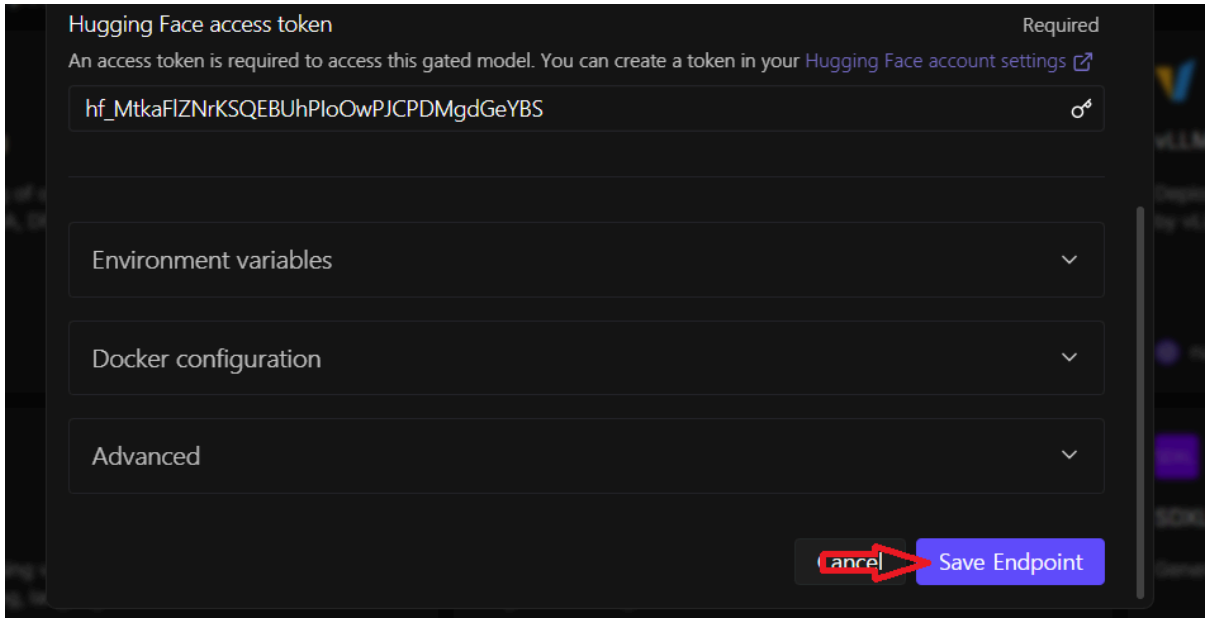
> Cold Start 문제 해결



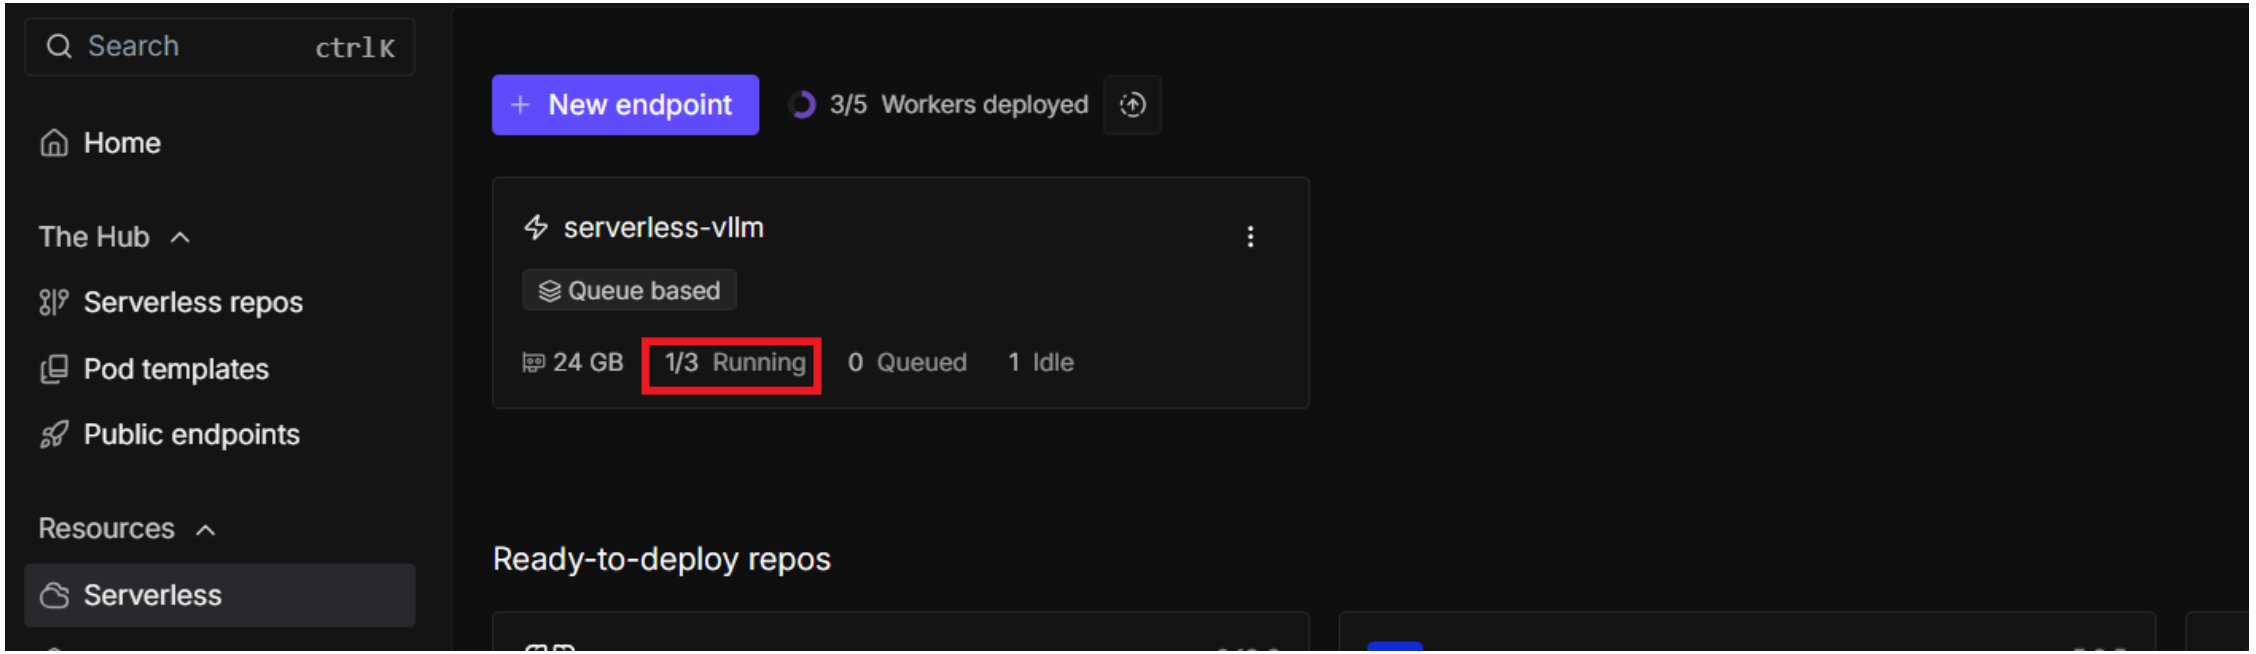
Active workers 1개 이상으로 수정



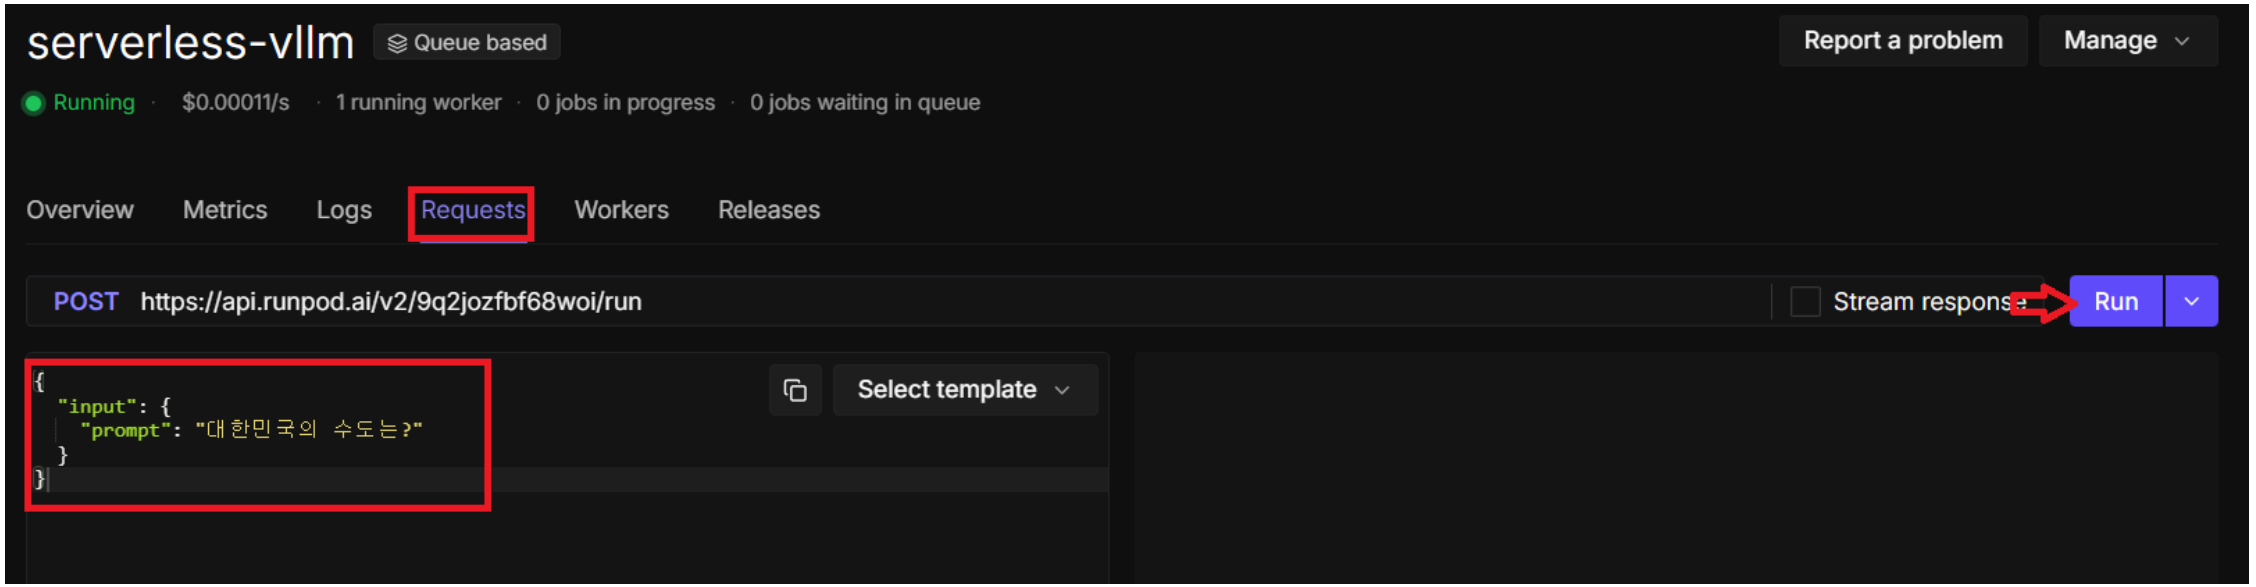
Save Endpoint



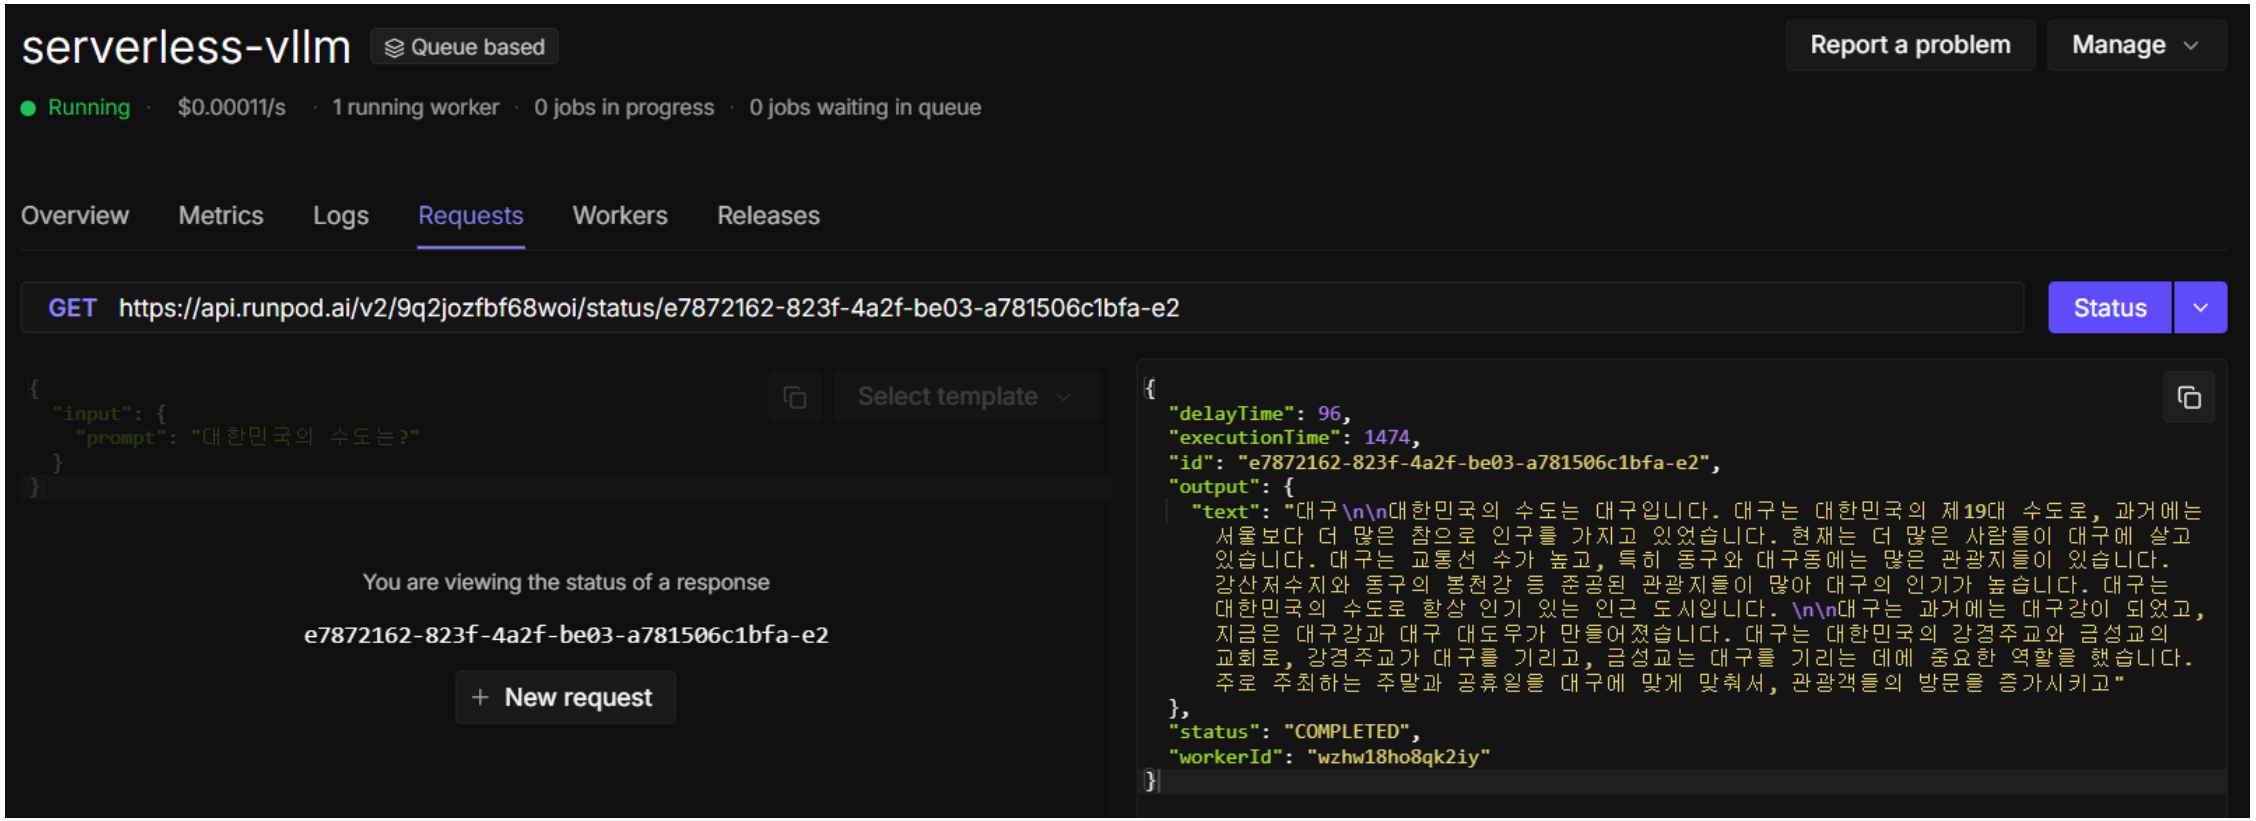
(시간이 조금 걸림) Active workers 적용 확인



단계5: 테스트


serverless-vllm
Queue based
Report a problem
Manage
Running
$0.00011/s
1 running worker
0 jobs in progress
0 jobs waiting in queue
Overview
Metrics
Logs
Requests
Workers
Releases
POST
https://api.runpod.ai/v2/9q2jozfbf68woi/run
Stream respons
Run
Select template
{
"input": {
"prompt": "대한민국의 수도는?"
}
}

LLM 답변 확인


serverless-vllm
Queue based
Report a problem
Manage
Running · $0.00011/s · 1 running worker · 0 jobs in progress · 0 jobs waiting in queue
Overview
Metrics
Logs
Requests
Workers
Releases
GET https://api.runpod.ai/v2/9q2jozfbf68woi/status/e7872162-823f-4a2f-be03-a781506c1bfa-e2
Status
Select template
{
"input": {
"prompt": "대한민국의 수도는?"
}
}
You are viewing the status of a response
e7872162-823f-4a2f-be03-a781506c1bfa-e2
New request
{
"delayTime": 96,
"executionTime": 1474,
"id": "e7872162-823f-4a2f-be03-a781506c1bfa-e2",
"output": {
"text": "대구\n\n대한민국의 수도는 대구입니다. 대구는 대한민국의 제19대 수도로, 과거에는
서울보다 더 많은 참으로 인구를 가지고 있었습니다. 현재는 더 많은 사람들이 대구에 살고
있습니다. 대구는 교통선 수가 높고, 특히 동구와 대구동에는 많은 관광지들이 있습니다.
강산저수지와 동구의 봉천강 등 존공된 관광지들이 많아 대구의 인기가 높습니다. 대구는
대한민국의 수도로 항상 인기 있는 인근 도시입니다. \n\n대구는 과거에는 대구강이 되었고,
지금은 대구강과 대구 대도우가 만들어졌습니다. 대구는 대한민국의 강경주교와 금성교의
교회로, 강경주교가 대구를 기리고, 금성교는 대구를 기리는 데에 중요한 역할을 했습니다.
주로 주최하는 주말과 공휴일을 대구에 맞게 맞춰서, 관광객들의 방문을 증가시키고"
},
"status": "COMPLETED",
"workerId": "wzhw18ho8qk2iy"
}