


# Web Crawling vs Web Scraping

- 웹 스크래핑(Web Scraping)이란 웹 사이트 상에서 원하는 정보를 추출하는 방법을 의미합니다.
- 웹 크롤링(Web Crawling)이란 웹 크롤러(web crawler)가 정해진 규칙에 따라 복수 개의 웹 페이지를 탐색하는 행위라고 하며, 웹 스파이더링이라고도 합니다.

| 크롤링                                               | 스크래핑                                         |
|---------------------------------------------------|----------------------------------------------|
| 웹에서 페이지 및 링크 다운로드<br>(웹을 기반으로 작동)                 | 웹을 포함한 다양한 소스에서 데이터 추출<br>(반드시 웹과 관련된 것은 아님) |
| 동일한 콘텐츠가 여러 페이지에 업로드 된 것을<br>인식하지 못하므로 중복 제거는 필수적 | 특정 데이터를 추출하는 것이므로<br>중복 제거가 반드시 필요한 것은 아님    |

자료 출처 : Data Scraping vs Data Crawling

- 하지만 요즘은 웹 크롤링 의 뜻이 확대되어 웹페이지 탐색 후 원하는 정보 추출(Web scraping) 하여 저장하는 것을 의미하는 경우가 더 많다.



<웹 크롤링과 웹 스크래핑의 차이>

# 웹 크롤링 주요 용도

- 웹 크롤링은 다양한 분야에서 활용되고 있다.
- 시장 연구, 경쟁사 분석, SNS 트렌드 파악 등 다양한 분야에서 크롤링을 활용해 데이터를 수집하고 분석하여 의사결정에 활용하고 있습니다.



<https://www.youtube.com/watch?v=ER27nPK28pg>

## 활용사례 1) E-commerce 사이트에서의 가격 정보 수집

- 온라인 쇼핑몰에서는 상품의 가격 정보를 주기적으로 업데이트한다.
- 크롤링을 통해 이러한 가격 변동을 실시간으로 파악하고, 경쟁사의 가격 전략을 분석하는데 활용될 수 있다.
- 이는 마케팅 전략 수립에 있어 중요한 역할을 한다.

## 활용사례 2) 소셜 미디어 데이터 분석을 위한 크롤링

- 소셜 미디어는 현재의 트렌드와 사회의 의견을 반영하는 중요한 공간이다.
- 특정 주제나 키워드에 대한 사람들의 반응을 파악하기 위해 크롤링을 통한 데이터 수집이 이루어진다.
- 이렇게 수집된 데이터는 다양한 분석 방법을 통해 유용한 인사이트를 제공한다.

## 웹 크롤링은 합법인가?



## 문제가 되는 크롤링

- 수집한 데이터의 상업적 이용
- 크롤링 과정에서 해당 서버의 문제 야기
- 수집한 데이터가 사용자의 민감한 정보인지
- 사이트의 이용방침, 의사(robots.txt, 이용목적)을 위반하지 않는지
  - 대부분의 웹사이트는 `robots.txt` 라는 파일을 통해 크롤러의 접근을 제어한다.

## 대표적인 국내 사례

### 잡코리아 - 사람인

- 원고 - 잡코리아 / 피고 -사람인
- (주)사람인의 웹사이트에 잡코리아의 채용 정보를 크롤링하여 기재한 사건
- 피고는 원고에 2억5천여만원 지급

### 야놀자 - 여기어때(진행중)

- 원고 - 야놀자 / 피고 -여기어때
- 야놀자의 제휴 숙박업소, 목록, 주소, 정보, 가격 정보 등을 API를 통해 크롤링하여 여기어때 서비스에 무단으로 복제한 사건


## 웹 크롤링 종류

- 웹 크롤링을 하면서 우리들이 만나는 페이지는 총 2가지가 있다.
- 하나는 정지해있는 의미의 정적(static) 과 다른 한가지는 움직인다는 의미의 동적(dynamic) 이다.

|         | 정적 수집               | 동적 수집                    |
|---------|---------------------|--------------------------|
| 사용 패키지  | requests / urllib   | selenium                 |
| 수집 커버리지 | 정적 웹 페이지            | 정적/동적 웹 페이지              |
| 수집 속도   | 빠름 (별도 페이지 조작 필요 X) | 상대적으로 느림                 |
| 파싱 패키지  | beautifulsoup       | beautifulsoup / selenium |

# 정적 웹 페이지 크롤링

- 정적 웹 페이지란 서버(Web Server)에 미리 저장된 파일이 그대로 전달되는 웹 페이지를 말합니다.
- 즉, 특정 웹페이지의 url 주소만 주소창에 입력하면 웹 브라우저로 HTML 정보를 마음대로 가져올 수 있습니다.



## 장점


- 요청에 대한 파일만 전송하면 되기 때문에 서버간 통신이 거의 없고 속도가 빠름
- 단순한 문서들로만 이루어져 있어서 어떤 호스팅서버에서도 동작 가능하므로 구축하는데 드는 비용이 적음

## 단점

- 저장된 정보만 보여주기 때문에 서비스가 한정적
- 추가, 수정, 삭제 등의 작업을 서버에서 직접 다운받아 편집 후 업로드로 수정해줘야 하기 때문에 관리가 어려움

# 동적 웹 페이지 크롤링

- 동적 웹 페이지란 입력, 클릭, 로그인 등 여러 이유로 동기/비동기 통신 형태로 서버(Was Server)와 데이터를 주고 받아 동적으로 제공하는 웹 페이지를 말합니다.



The screenshot shows a web browser window with the address bar displaying 'nid.naver.com/nidlogin.login'. The page features the Naver logo at the top center. Below the logo, there are three tabs for login methods: 'ID 로그인' (selected), '일회용 번호' (One-time code), and 'QR코드' (QR code). A notification bubble above the QR code tab states 'PC방 등 공용PC라면 QR코드 로그인이 더 안전해요.' (If you're at a PC bang or public PC, QR code login is safer). The 'ID 로그인' tab contains two input fields: '아이디' (ID) and '비밀번호' (Password).

## 장점


- 다양한 정보를 조합하여 웹 페이지를 제공하기 때문에 서비스가 다양함
- 추가, 수정, 삭제 등의 작업이 가능하기 때문에 관리가 편함

## 단점


- 웹 페이지를 보여주기 위해서 여러번의 비동기 통신을 처리하기 때문에 상대적으로 속도가 느림

## 동기와 비동기 통신 방식 차이

- 동기식은 요청 후 응답을 받아야지만 다음 동작이 이뤄지고 비동기식에서는 요청을 보낸 후 응답과는 상관없이 동작하는 방식이다.



<동기식>



<비동기식>

## Playwright

- 마이크로소프트에서 만든 웹 브라우저 자동화 도구
- Python, JavaScript, Java, C# 등 여러 언어 지원
- 웹페이지 테스트, 스크래핑, 자동화 작업에 사용

## Playwright vs Selenium

| 용도                                 | 추천 도구             |
|------------------------------------|-------------------|
| 복잡한 크로스 브라우저 테스트 + 모바일 Safari까지 필요 | <b>Playwright</b> |
| 다양한 언어 지원, 레거시 코드 유지               | <b>Selenium</b>   |
| 최신 웹앱 자동화, CI/CD 테스트 속도 중요         | <b>Playwright</b> |
| 오래된 자동화 환경 유지보수                    | <b>Selenium</b>   |

# 주요 크롤링 모듈(라이브러리)

## requests

- 파이썬 HTTP 통신에 사용되는 모듈
- 설치방법: `pip install requests`

## beautifulsoup

- HTML, XML, JSON 등 파일의 구문을 분석하는 모듈
- 설치방법: `pip install beautifulsoup4`

## selenium

- 웹 브라우저를 이용하는 자동화 프로그램입니다.
- 설치방법: `pip install selenium`

## playwright

- 웹 브라우저를 이용하는 자동화 프로그램입니다.
- 설치방법
  - 윈도우 C++ 설치
  - `pip install pytest-playwright`
  - 브라우저 driver 설치방법: `playwright install chromium`